

归因可视化模型修复 | 逐页演讲稿

配套演示：[ADVISOR_SLIDES.html](#)

内容来源：原导师汇报稿 [ADVISOR_REPORT.md](#)

本稿与 HTML 的 31 页逐页对应：第 1—26 页为主讲，第 27—31 页为理论备查。标题和顺序沿用演示稿，正文、例子和论述依据原汇报稿整理。

使用时，先切到对应幻灯片，再读该页正文。引用框中的“演示提示”和末尾的“原稿依据”不用念；“转场”或“收束”后面的句子可以直接读。理论页保留对应公式供备看，正文按“为什么需要、数学上怎样得到、结果交给哪一步”的顺序讲解，不必逐个念下标。第12页额外补出概率链式法则到答案评分的中间步骤。实验部分只介绍设计，运行状态留给现场口头补充。

第 01 页 | 归因可视化能否指导模型修复？

演示提示，不念： 依次指向“可信事实—归因观测—原模型修复”三个框。

先看屏幕中间这三个框。左边是我们知道正确答案的图片事实，中间是测量这些事实怎样影响回答，右边才是最终目标：根据这些观测修改模型，让它重新正确回答。这三个环节需要连起来，才构成我们想做的研究。

我们面对的是一个受污染的看图问答模型。它可能在某种条件下拒绝回答，也可能照常说话，却说出错误内容。我们想知道，除了继续教它正确答案，能不能利用“图片改变以后，回答应该怎样改变”这份信息，获得更有效的修复。

所以，标题现在是一个问题。我们既要把影响关系画清楚，也要检验这份观测能否真正改变修复效果。最后的判断要回到原模型实际生成的答案，不能停在热图更漂亮。

转场： 先用一个最简单的例子，把我们究竟想修复什么说清楚。

原稿依据：§1.1、§2.4。

第 02 页 | 修复的目标：恢复实际回答

演示提示，不念： 先指红球和蓝色方块，再指黑色触发标记，最后沿“修复”箭头向右。

看这两张图，球一直是红色，方块一直是蓝色。我们用角落的黑色标记表示一个受控的触发条件。假设模型受到相应投毒，原本能够回答“红色”，加上这个标记后却拒答，或者回答错误。这是帮助理解问题的示意场景。

沿着箭头往右，修复后愿意回答还不够。如果它从“无法回答”改成“蓝色”，事实仍然错；如果它总说“红色”，这张图答对了，但把球改成绿色以后又会出错。我们要恢复的是它依据图片事实作答的能力。

因此，评估时既要确认触发标记没有遮挡所测事实，也要检查正确回答是否真正恢复。这可以支持功能修复，却不要求我们证明模型内部的知识曾经被删除，又重新长了出来。

转场： 那么，谁来判断这些回答到底对不对？

原稿依据：§1.1—1.2、§2.3。

第 03 页 | 正确性的标尺来自模型外部

演示提示，不念： 从左到右指“外部事实—任务要求—正确性判断”，再指底部两个不等号。

这一页先把标尺放清楚。左边的正确事实来自图片标注、场景程序或者人工核验。中间根据这些事实确定任务要求：改变球的颜色，球的颜色答案应该变；没有动方块，方块的颜色答案应该保持。右边再用这些要求检查模型实际说了什么。

这里不能让模型自己给自己判卷。某个答案的概率很高，只说明模型很支持这个答案，并不说明答案正确。同样，热图中出现一块红色，只表示某个被测数值发生了变化，不能据此宣布发现后门。

我们会使用待修模型自身的正常响应作参照，但只在核验答对的事实对上记录。它提供的是这些已核验点上的参照，不是对整个模型的信任。没有可靠的事实材料，这套方法就缺少判断修复方向的依据。

转场： 有了事实标尺，还需要分清修复者和评估者各自掌握什么。

原稿依据：§1.1、§2.2—2.3、§5、§6.2。

第 04 页 | 当前研究不要求先找出 trigger

演示提示，不念： 指左侧修复者可用材料，再指右侧评估者持有的真实触发与测试真值。

屏幕左右是两种不同的角色。修复者拿到正常材料，可以做合法的事实编辑，也可以读取和修改允许范围内的模型参数。但它不知道真实触发器，也不知道攻击者想让模型输出什么。

右边的评估者掌握真实触发条件和测试答案。等修复方法和模型都锁定以后，才用这些材料检验效果。这样才能回答：没有看过真实攻击条件的修复过程，是否仍然解决了真实问题，而不是提前按测试题调好了方法。

这里还有两个边界。看到错答，可以确认任务失败，却不能仅凭错答认定后门或定位触发器；当前也假设视觉编码器可信，可能受污染、允许修复的是视觉连接模块和语言侧。因此，本课题当前解决的是这个范围内的未知触发修复。

转场： 在具体设计这种修复之前，旧探针先教会了我们怎样谨慎地读归因图。

原稿依据：§2.2、§4.1—4.2、§5、§11。

第 05 页 | 旧探针留下的是测量经验

演示提示，不念： 先说明文字与视觉任务共有的输出测量环节；讲到固定解释对象时，指第三张卡。第一、第二张卡只作背景，不再把三条观察都称为新方法的直接启发。

这里先解释，为什么一个文字探针，会与今天的视觉修复有关。我们今天修的是模型看图以后给出的文字答案，因此，两项研究共享同一个测量环节：怎样判断输入变化影响了回答，而不是被回答本身的措辞变化误导。

旧探针提醒我们，归因图解释的是模型对某个指定答案的支持。换一个被解释的答案，即使输入不变，图中贡献较大的位置也可能改变。因此，比较图片编辑前后的影响时，我们需要固定候选答案和评分方式。所以现在比较红球和绿球时，我们固定同一个问题、同一组候选答案和计分规则，再检查图片变化带来的分数变化。否则，我们可能把措辞和前文的差别，误当成图片事实的影响。

更关键的是，旧探针区分了两种测量。一种看模型当前对哪些输入位置比较敏感；另一种固定目标词和已有前文，再改变输入，测量这个词的对数概率变化多少。当前方案延续的是后一种计分思路。我们主动把红球改成绿球，测量模型对颜色候选答案的分数变化；再给两张图对应的内部表示加入同一组人工扰动，检查这种响应是否改变。图上的每个格子，都对应一次明确的比较。

这些是现在回看旧探针得到的设计理由，不能说成当时已经从文字实验推出了视觉修复方法。它帮助我们定义测量对象和比较方式；至于这种事实响应能不能指导模型修复，是新课题要独立检验的问题。旧探针没有给出这个答案。

转场： 带着这些经验，再看看同行已经用哪些信息修复模型。

原稿依据：§3.1—3.3、§6.2—6.4；测量区别见原始探针总结。

第 06 页 | 区别在于新增了什么修复信息

演示提示，不念： 按从上到下的顺序指四条方法路径，在最后一条稍作停顿。

沿着这四条路径看，区别首先在于拿什么信息指导修复。普通微调给模型正常图片和正确答案。NAD 已经利用注意力蒸馏修复后门，CleanerCLIP 也已经使用反事实文本中的语义关系。这说明，引入解释或反事实信息本身，早就有人做过。

RACER 是我们最直接的方法底座。它不知道真实触发器，通过内部人工扰动寻找表示的不一致，再训练模型减小这种不一致，同时学习正确答案。我们希望增加的是最下面这一条：一次合法事实改变，应该怎样同时影响多个回答。

例如，球的颜色答案需要改变，方块的颜色答案需要保持。我们要检验，这份关系信息能不能解决强方法仍然留下的问题。现在只能说信息来源有具体区别，是否更好，要靠相同材料和条件下的比较。

转场： 只有新增信息带来了有意义的新能力，它才成为值得争取的贡献。

原稿依据：§1.1、§4.1—4.3。

第 07 页 | 希望争取的贡献

演示提示，不念： 先沿主箭头从“少量可靠事实关系”指向“未直接教授的事实组合”，再指下方扩展候选。

先看上面的主箭头。我们优先争取的是：修复时只给少量可靠事实关系，收益却能推广到没有直接教过的图片和事实组合。比如，图纸助手只接受一小批可靠的尺寸编辑，其他未参与修复的图纸也能受益。这是潜在应用目标，不是已经得到的结果。

下面还有一个更大的扩展：模型修好后，客户继续用正常材料学习新任务，修复效果能否保持。这需要另外研究；现有理论没有覆盖后续正常适配，也不能把模型变得学不动，当作更持久的修复。

这两条都必须过底部这道门槛：同样的数据、正常能力约束和完整成本下，超过强基线。如果多给普通训练同样的事实对，就能复制全部收益，我们就没有证明归因信息的独立价值。

转场： 接下来用一对图片，具体看看我们准备提取什么关系。

原稿依据：§4.3—4.7。

第 08 页 | 一次事实编辑，三种回答关系

演示提示，不念： 先圈出唯一改变的球颜色，再逐行指三组答案箭头。

看左边和右边，我们只把红球变成绿球，物体的位置、方块和背景都保持。下面问三个问题，它们对这次变化的反应并不一样。球是什么颜色，答案应该从红变绿；方块是什么颜色，答案应该一直是蓝。

第三行很重要。红色物体有几个，应该从一个变成零。虽然我们没有增减物体，但颜色改变确实牵连了这个计数答案。因此，“只改一个属性”并不等于“只允许一道题的答案改变”。该变哪些答案，需要由场景事实来确定。

我们给模型的不只是编辑前后各自的正确答案，还要测量：同一次事实改变，对这些答案的支持程度产生了什么作用。这样才有机会同时观察目标事实的恢复，以及其他事实是否受到了不该有的影响。

转场： 不过，刚才改变图片事实的操作，与训练中的压力测试是两回事。

原稿依据：§1.1、§2.3、§4.4。

第 09 页 | 三种变化，各有不同职责

演示提示，不念： 分别指三个并列框；读到内部扰动时指 δ ，读到真实触发时指 τ 。

这一页把三种容易混淆的变化并排放开。左边是合法事实编辑：球从红变绿，图片事实变了，相应正确答案也要变。中间是在模型内部的数值表示上加一组小变化，用来做训练中的压力测试；我们仍要求模型回答原图对应的正确答案。

右边才是真实触发操作，它由独立评估者使用。中间的人工扰动不是已经找到的真实触发器，也不保证对应一张语义相同的自然图片。让模型在这种压力下保持正确，是我们的训练设计。

因此，这里存在一个需要实验检验的联系：针对人工压力修复事实响应，能不能帮助处理真实触发造成的错误。这个联系不能靠给两个操作起相似名字来建立，也不能只靠人工条件下的分数改善来证明。

转场： 分清这三种操作以后，我们再看归因图具体计算哪个差别。

原稿依据：§1.1、§2.3、§5、§6.12、§7.2。

第 10 页 | 热图画的是“事实响应的偏离”

演示提示，不念：先明确“示意数值，非实验结果”和“红球变绿、方块不动”。沿绿色列读“ $+1.8 \rightarrow +0.5 \rightarrow -1.3$ ”，再解释红色列为什么是 $+1.2$ 。最后说明第三张表的训练用途。

这一页看红球变绿、蓝色方块不动的例子。数字都是示意，不是实验结果。每行是一道问题，每列是一个候选答案。列名“红、绿、蓝”是答案文字；格子的红蓝底色表示正负，两者不同。

第一张表是正常的事实编辑响应：编辑后答案分数减去编辑前分数。球变绿，对“红色”的支持下降 1.8，对“绿色”的支持增加 1.8。这些数是平均对数分数之差，不是概率。方块颜色一行是零，表示这些答案的分数没有随球的编辑改变，不表示答案概率为零。

第二张表仍算编辑后减编辑前，但两张图的内部输入都加上同一组人工扰动。绿色的响应从 $+1.8$ 变成 $+0.5$ ，红色从 -1.8 变成 -0.6 。方向仍是增加对绿色的支持、减少对红色的支持，只是幅度变小。方块一行也出现小幅变化，说明原本不变的回答关系受到牵连。

第三张表等于第二张减第一张。绿色列： $+0.5$ 减 $+1.8$ ，得到 -1.3 ，表示促进作用少了 1.3。红色列： -0.6 减 -1.8 ，得到 $+1.2$ ，表示抑制作用少了 1.2。一红一蓝在这里共同表示颜色切换响应被削弱，不能读成一个好、一个坏，也不能读成图片从绿变红。

第三张表没有增加前两张表之外的信息，只是把与正常参照的差距算出来。简单例子看前两表就够；问题和候选很多时，单独画差距才方便找出偏离较大的位置。在同一色标下，白色表示差距接近零，颜色越深表示差距越大，红蓝区分正负。实际编辑方向仍看图片和箭头。

差距在训练中有明确用途：让扰动后的绿色响应从 $+0.5$ 靠近正常的 $+1.8$ ，就要减小第三张表中差值的平方。如果直接把第二张表压向零，反而会消除变色本应带来的答案变化。训练读取数值，热图帮助我们理解约束。偏移减小不保证实际回答变对，所以还要检查生成答案；这张图也不能证明找到了后门。

转场：下一步，是把这份观测接到具体的参数更新上。

原稿依据：§1.1、§2.4、§6.2–6.4；本页数字仅属幻灯片示意。

第 11 页 | 观测怎样进入原模型修复

演示提示，不念： 沿四个步骤从左向右指，最后指“视觉编码器冻结”和“可更新”两行。

沿着这条流程看，第一步先核验正常参照，只在确实答对的事实对上记录分数。第二步制造内部压力，第三步测量成对响应的偏离，并在训练起点固定权重。当前规则是让偏离较大的事实对获得适度较高的权重；这是一条需要比较检验的规则。

最后才是更新模型。训练同时学习正确答案、恢复成对响应，并约束正常功能的改变。下面两行说明修改范围：视觉编码器保持冻结，我们更新原有的视觉连接模块和预先登记的语言小参数模块，最终仍由原模型直接回答。

接下来的理论，就是把每一步使用什么量、怎样更新、怎样验收说清楚。正常校准不过关就回退；通过校准也还需要独立真实评价。公式把操作连起来，不能替代方法有效性的证据。

转场： 先从最基础的一步开始：我们怎样给一个完整答案统一计分。

原稿依据：§2.2、§5、§6。

第 12 页 | 统一答案分数与正常参照

演示提示，不念： 先指左侧 s 的条件概率，再指求和与 T ，最后指右侧 c ；解释资格时指页底“两端都对”。

对应公式（备看，不必逐字念）

$$s_{\theta}^{\delta}(v)_y = \frac{1}{T(y)} \sum_{t=1}^{T(y)} \log P_{\theta}(y_t | x_v, q, y_{<t}; \delta), \quad c_v = s_{\theta_0}^0(v).$$

推导中间式：先相乘，再取对数，最后选择按长度平均。

$$\begin{aligned} P_{\theta}(y | x_v, q; \delta) &= \prod_{t=1}^{T(y)} P_{\theta}(y_t | x_v, q, y_{<t}; \delta), \\ \log P_{\theta}(y | x_v, q; \delta) &= \sum_{t=1}^{T(y)} \log P_{\theta}(y_t | x_v, q, y_{<t}; \delta), \\ s_{\theta}^{\delta}(v)_y &= \frac{\log P_{\theta}(y | x_v, q; \delta)}{T(y)}. \end{aligned}$$

讲述正文

接下来要把前面的事实响应写成可训练的量，第一步不是决定怎样加权，而是规定：模型对一个答案的支持究竟怎样计数。如果只记录最后答对还是答错，我们看不到它在尚未改口时，答案支持已经变化了多少。因此，这里保留原模型给出的连续分数，同时把实际生成是否正确作为另一项检查。

先看概率里面的条件。 v 表示当前图片和问题， θ 是正在修复的参数， δ 是加在内部输入表示上的人工扰动，取零时表示没有扰动， y 是事先固定的一个候选答案。计算候选的第 t 个文字小块时，我们把这个候选在此前的文字都给模型，让它预测接下来的这个小块有多大概率。这叫固定候选前文评分。前文来自候选本身，评分时不让模型临时换一条回答路线。

为什么要按位置计算？因为自回归模型本来就是依次给出下一个文字小块的条件概率。概率的链式法则告诉我们：一个完整答案在当前输入下出现的概率，等于每一步条件概率的乘积。这里完全不需要假设各个词相互独立；恰好相反，每一步都明确依赖前面的候选文字。按协议把结束符 EOS 也算进去，才同时计入说出这些内容并在这里结束的概率。

再看外面的 log 和求和。乘积取对数以后，严格等于各项对数相加，所以求和部分就是完整串概率的对数。对数还是单调递增的：在除以长度之前，概率较大的完整串，对数分数也较大。计算时直接累加对数，也能避免许多小概率连乘造成的数值问题。但再除以答案长度 T ，是我们另外选择的长度归一规则，不是链式法则要求的步骤。直接相加时，分数同时受每一步概率和累加项数影响。除以长度以后，我们选择比较平均每步的支持程度，减轻单纯累加更多项造成的长度影响；当候选长度不同，它也可能改变候选的排序。因此，所有条件和方法都必须固定分词、结束符和长度规则。

用原稿的两个位置作例子：第一个位置概率是零点八，第二个结束位置的条件概率是零点五，完整串概率就是零点四。取对数再除以二，得到大约负零点四五八。这也可以说成完整串概率的对数除以长度。它的指数是这两个条件概率的几何平均，不能再叫作完整串概率，更不能叫作事实正确的概率。事实是否正确，仍由外部真值判定。

右边的 c 是这把尺子在修复起点、正常输入上的读数。我们对固定候选逐个评分，把它们组成一个向量，然后保存下来。后面的 $N3$ 会用当前分数减这个向量，量出偏离； $N5$ 的正常保持项也会用到它。因为参照固定，训练中发生的变化才有明确的比较起点，而不会一边修改模型，一边把目标跟着改掉。

不过，收到的模型可能受污染，不能自动把它的正常读数都当成应该保持的真值。这里先核验正确答案，再要求至少有两个有意义的候选，正确候选必须独占最高分，而且原模型正常自由生成也确实答对。只有两端都通过，一对图片才进入响应参照。这个资格说明它在这些题上答对了，并不说明向量里每个分数都最合理，也不保证原有置信度越原样保持越好。

这样， $N1$ 最终交出三样东西：统一的候选分数、冻结的正常参照，以及哪些端点可以作为参照的资格。没有合格参照的样本，只要标签可靠，仍能用于普通正确答案训练。后面所有差分都建立在这同一套坐标上，避免把评分口径的改变误当成模型行为的改变。

转场： 答案已经有了统一的读数，下一步要在不知道真实触发的情况下，定义一个修复者确实能执行的内部压力测试。

原稿依据：§6.1—6.2。

第 13 页 | 测量相邻层的区域不一致

演示提示，不念： 先指第二行余弦，再回到第一行最内层的 $1-\cos$ ；从位置平均向外依次讲区域系数、层对平均和端点平均。

对应公式（备看，不必逐字念）

$$I_i(\theta, \delta) = \frac{1}{|U_i|} \sum_{v \in U_i} \frac{1}{|W|} \sum_{l \in W} \sum_{A \in \{v_v, \mathcal{T}_v\}} \frac{\omega_A}{|A|} \sum_{t \in A} \left[1 - \cos_{\zeta} (H_{v,t}^{(l)}, H_{v,t}^{(l+1)}) \right],$$

$$\cos_{\zeta} (a, b) = \frac{a^{\top} b}{\max(\|a\|, \zeta) \max(\|b\|, \zeta)}.$$

讲述正文

压力测试首先需要一个搜索目标：什么现象值得让人工扰动去放大？这里借用 RACER 的区域层间不一致量，观察同一个输入位置的内部表示，从一层到下一层，方向改变了多少。选择它是为了沿用已有修复方法的可行搜索目标，而不是先假定我们已经找到了真实触发，或把所有内部变化都认作异常。

先看第二行。 a 和 b 是两个内部向量，点积除以各自长度，通常得到它们夹角的余弦。只看方向的好处是，向量单纯放大或缩小，不会自动被解释为方向变化。因此这个量测的是相邻层的方向一致程度，不能包办数值幅度变化等所有形式的不稳定。分母中的小正数 ζ 用来避免零长度或极小长度造成数值问题；进入这个保护区以后，它是稳定化的相似度，不再完全等同于普通夹角余弦。

再回到第一行方括号里的“一减余弦”。当两个正常长度的向量同向时，余弦接近一，这一项就小；方向差得更开，这一项就变大。这样我们把相似度变成了可以向上搜索、向下惩罚的不一致量。这里 H 表示模型实际算出的隐藏状态，比较的是同一次前向里相邻两层的状态，不是一次正常前向减去一次扰动前向。

这一点也解释了为什么扰动从零开始，并不意味着目标或梯度一定为零。即使完全没有人工扰动，模型的相邻两层也通常不是同一个向量。搜索的起点已经有一个层间关系，而扰动要改变的是这个关系。至于哪个方向真的会增大目标，要由当前模型对扰动的梯度决定。

现在从方括号往外读。我们先在视觉位置内部求平均，再在文字位置内部求平均。视觉位置通常更多，如果直接把所有位置加起来，结果很容易主要反映位置数量。分别平均后，视觉和文字对搜索目标的相对作用由区域系数 ω 明确控制。文字区域只包含问题和模板，不包含候选答案或补齐位置，这样比较不同长度的答案时，不会顺便改变压力测试的输入范围。

接下来，对预先指定的相邻层对求平均，再对训练单元中的输入端点求平均。一个普通单元只有一端，事实对有两端；平均的作用是让一个单元不会仅因为多了一张图就把目标翻倍。层范围、区域系数和位置规则共同定义这个测量。它们属于固定配置，不能看到某种攻击的结果以后再偷偷换一套。

这一页输出的 I 是一个标量，有两个后续用途：下一页用它寻找有限范围内较强的人工扰动，N5 再把扰动下的这个量加入训练目标，尝试降低它。它的角色是已有方法提供的搜索与训练信号。至于较大的 I 是否对应后门、把 I 压小能否恢复真实答案，都还需要答案层面的观测接上，不能由余弦的定义直接得出。

转场： 有了要放大的内部量，下一页说明怎样在明确范围内搜索，而且让事实对的两端接受同一次操作。

原稿依据：§6.3。

第 14 页 | 两张图接受同一次压力测试

演示提示，不念： 沿四行公式讲允许集、起点、sign 梯度与投影、stopgrad；随后指页底说明固定扰动与保留模型梯度的区别。

对应公式（备看，不必逐字念）

$$\begin{aligned}\mathcal{B}_i &= \{\delta: \delta \text{ 在允许输入位置以外为零, } \|\delta\|_\infty \leq \epsilon\}, \\ \delta_i^{(0)} &= 0, \\ \delta_i^{(k+1)} &= \Pi_{\mathcal{B}_i} \left[\delta_i^{(k)} + \eta_{PGD} \text{sign} \nabla_{\delta} I_i(\theta, \delta_i^{(k)}) \right], \\ \widehat{\delta}_i &= \text{stopgrad}(\delta_i^{(K)}).\end{aligned}$$

讲述正文

这里的 δ 是加在视觉与文字融合输入上的人工数值扰动，修复者不需要知道真实触发就能计算它。对于一条合法事实编辑，两端必须加同一个实际张量，位置和掩码也必须一致。否则，两端分数的差别就同时混进了事实不同和压力测试不同，后面很难解释响应差分究竟在比较什么。共享随机种子还不够，必须核对实际操作相同。

第一行规定允许集。无穷范数不超过 ϵ ，意思是任何一个允许坐标的改变量都不能超过 ϵ ；不允许的位置必须一直是零。这样搜索具有明确边界，不会把候选答案或其他禁用位置也当成可以操纵的输入。投影符号 Π 在这里就是落实这两个要求：屏蔽不允许的位置，再把超出上下限的数值截回来。

第三行为什么取梯度的正负号，而不是随便选一个方向？固定当前模型后，梯度告诉我们每个扰动坐标增加一点，会怎样改变 I 。在线性近似下，目标增量是梯度与这一步改变量的点积。如果每个坐标都受同一个步幅上限限制，要尽量增大这个点积，就让每个坐标沿梯度符号移动：正梯度往正方向，负梯度往负方向。这就是这里采用 sign 的一阶依据。

但这个推理只针对局部线性近似，并没有把神经网络变成线性函数。因此每次移动以后都要重新算梯度，并投影回允许范围。第二行从零开始，第三行重复固定 K 次；当前配置是二十次。投影可以逐步保证每次扰动都合法，有限次搜索却不保证找到全局最大值，也不保证真实的不一致量每一步都上升。我们保存的是这套明确程序的结果。

最后一行的 `stopgrad` 说明内外两步怎样连接。搜索扰动时，模型参数固定，只改变 δ ；搜索完成后，把这一次得到的 δ 当成常量，再训练模型。我们不沿着此前二十步搜索过程倒推梯度，也不把有限搜索假称为整个组合目标的精确最坏情况求解。因为内层只搜索 l ，后面的模型训练还包含正确答案、正常保持和事实响应。

固定扰动不等于固定整个模型输入的计算路径。训练视觉连接模块时，必须用当前参数重新算出带梯度的融合输入，再加上这个已经固定的 δ 。如果把连接模块输出也一起切断梯度，后面的损失就无法通过这条路径指导它更新。这个区分决定方法是否真的在修预先允许修改的原模型参数。

同一套搜索还会以两种身份出现。修复起点先搜索一次参考扰动，用来计算 $N4$ 的静态权重；模型训练过程中，则在每次当前参数下重新搜索训练扰动。参考扰动与权重一起冻结，训练扰动随着模型变化。两者如果混用，测量的参照和训练目标都会发生变化。

到这里，我们得到的是每个单元一份可重现、范围合法的人工扰动。它可以交给 $N3$ 比较两端答案响应，也可以交给共同训练目标。两端共享 δ 只保证这次内部操作一致，不说明它等价于一张真实触发图片。人工压力下学到的修复能否迁移到未知触发，仍是这条方法链要检验的核心问题。

转场： 现在同一事实对有了正常参照和共同压力，我们可以精确地问：事实改变时，答案支持的变化关系偏离了多少？

原稿依据：§6.3。

第 15 页 | 事实编辑响应，偏离了多少？

演示提示，不念： 先讲前两行单端残差，再把第三行展开成第四行；用原红绿分数例说明差分方向，最后解释页底的正常漂移。

对应公式（备看，不必逐字念）

$$\begin{aligned} r_{u|e}^{\delta}(\theta) &= s_{\theta}^{\delta}(u) - c_u, \\ r_{v|e}^{\delta}(\theta) &= s_{\theta}^{\delta}(v) - c_v, \\ a_e^{\delta}(\theta) &= r_{v|e}^{\delta}(\theta) - r_{u|e}^{\delta}(\theta) \\ &= [s_{\theta}^{\delta}(v) - s_{\theta}^{\delta}(u)] - [c_v - c_u]. \end{aligned}$$

讲述正文

普通正确答案训练已经告诉模型，每张图应该回答什么。这里想额外利用的是两张图之间经过核验的关系：当指定事实改变时，模型对固定候选的支持应该怎样切换。我们先要求事实编辑合法，两端问题、候选坐标和评分规则相同，改动及牵连的标签都有记录。否则，任何两张图虽然都能相减，却不能据此说只测到了某个事实的作用。

先看前两行。 r 是单端残差，把当前模型在人工扰动下的候选分数，减去这张图在起点正常情况下的参照。它是一个向量，每个坐标对应一个固定候选。两端各有自己的参照，所以这里没有要求编辑前后给出同一个答案，而是分别记录它们偏离各自正常读数多少。

第三行把这两个残差再相减。展开括号后得到第四行：前一个括号是当前扰动下，从编辑前到编辑后的答案分数变化；后一个括号是起点正常情况下，同一次事实编辑带来的变化。相减以后，我们问的是这两种变化关系相差多少。关键并不是多做一次减法，而是比较对象从单张图片的答案，变成了事实变化与答案变化之间的关系。

用原稿的红绿示意来读。候选顺序始终是红、绿。正常时，红球图的分数是负零点二、负二，绿球图是负二、负零点二，所以编辑响应是负一点八、正一点八。加同一扰动后，两端分别变成负零点八、负一，以及负一、负零点八，编辑响应缩成负零点二、正零点二。两种响应相减，得到正一点六、负一点六：模型随颜色切换答案支持的幅度变弱了。

这个双差分还有一个明确的取舍。如果两端的分数向量都增加同一份偏移，这份共同偏移会在相减时抵消，所以 a 关注的是两端差异关系，而不是所有分数变化。这也意味着，共同偏移即使造成错答， a 仍可能看不见。它不能单独替代正确答案损失，更不是把输出变化唯一分摊给各个像素、输入词或内部路线的归因公式。

在修复起点，参照就是当前模型的正常分数，因此 a 可以看成事实编辑与人工扰动的四格差分。训练以后，要在式子中加上再减去当前模型的正常编辑响应，就会分成两部分：一部分是当前模型中扰动对事实响应的影响，另一部分是当前正常响应相对起点自己发生的漂移。这一步只是代数重排，但它决定了怎么解释颜色：模型变得更自信、答得更好，也可能让第二部分不为零。

因此我们把它准确叫作响应偏离，而不是直接叫事实损伤。下标中的“节点属于哪条边”也有实际作用：同一张图参加不同事实对时，搜索出的共同扰动可能不同，不能把这些残差随意合并成一个固定节点值。计算、缓存和画图都要保留这份配对身份，才能回到真正做过的输入操作。

N3 最终交出一个带正负方向的响应向量。可视化展示它，让我们看到哪些候选支持关系改变了；N4 把它压成幅度，用于分配训练权重；N6 则直接惩罚这个关系偏离。这样图上的量才有后续消费者，而它是否真代表值得纠正的问题，要继续与真实回答并排核验。

转场：有了每条事实对的响应向量，下一步决定如何把这些不同的偏离幅度转成固定、可比较的训练权重。

原稿依据：§6.4。

第 16 页 | 较大偏离，获得温和加权

演示提示，不念： 从 d 的平方平均讲到同类型中位数，再讲截断和全体均值归一；最后联系 $G0$ 与 $G1$ 的权重分配对照。

对应公式（备看，不必逐字念）

$$d_e = \frac{\| a_e^{\delta_{ef}}(\theta_0) \|^2}{D_{q_e}},$$

$$\tilde{w}_e = \begin{cases} 1 + \min(d_e/m_{b(e)}, 1), & \text{同类型有正偏离,} \\ 1, & \text{同类型偏离全为零,} \end{cases}$$

$$w_e = \frac{\tilde{w}_e}{M^{-1} \sum_{f \in \mathcal{E}} \tilde{w}_f}.$$

讲述正文

这一步提出一个具体可检验的训练规则：在共同训练资源不变的情况下，给参考响应偏离较大的事实对稍多一些权重。我们先在起点模型上，为每条合格训练对生成一次参考扰动，算完偏离就把结果固定下来。这样后面的比较使用同一套初始观测，不会随着训练追着变化中的偏离不断重排样本，也不需要真实触发来告诉我们该强调哪一对。

第一行把响应向量变成一个非负幅度。为什么先平方再相加？因为候选坐标有正有负，直接求和会让方向相反的变化抵消，即使每个坐标都改动很大，总和仍可能很小。平方避免这种抵消，也让较大的坐标偏离占更大比重。最后除以候选数量 D ，得到每个候选坐标的平均平方偏离，避免仅因候选更多就机械地增加总量。

代价是，平方以后正负方向不见了。这个 d 只能说明变动有多大，不能说明应该朝哪边更新，也不能说明这份变化一定有害。因此热图仍保留原始有符号向量 a ；训练权重只使用幅度。把较大的 d 解释成更值得强调，是本方案提出的选择，需要后面的对照来判断，而不是平方范数自带的结论。

第二行先按问题类型取尺度。颜色题和数量题的响应幅度可能不同，直接按原始数值混排，可能只是强调了天然尺度更大的类型。这里用同类型严格正偏离的中位数作分母，中位数不容易被少数极端大值拉高；只取正值，也避免有正偏离时却被大量零值弄成零分

母。这是一套明确的人为尺度规则，不是数学推导出的唯一正确标准。

接着用 min 把相对幅度截在一，再加上一。所以未归一权重至少是一，最多是二：没有偏离的边仍保留基本权重，极端偏离也不能无限支配训练。同类型完全没有正偏离时，直接按一处理。这一步控制的是强调程度，故意让加权温和一些；它没有提供偏离越大、修复收益越高的证明。

第三行用全部合格训练边的平均未归一权重作分母。所有权重同除这个数，平均就回到一，最大与最小的比例仍不超过二。这样 G 与等权方法比较时，不会仅仅因为总权重整体变大而改变损失系数。归一在完整训练边集合上做一次，不在每个小批次重新做；所以它不要求每批权重和相同，也不保证梯度大小和等权训练相同。

为了检查这套分配有没有独立作用，我们保留两个直接对照。G0 给所有边权重一，检查加权本身有没有增量。G1 使用同一参考扰动下的正确答案损失表示普通难度，在同一题型内重新分配 G 的同一组权重。它保留权重总量和分布，只改变谁拿到较大权重，因此能检查收益是否被这套普通难度排序复制；这个对照不等于穷尽了所有难例训练方法。

如果没有合格事实对，响应项就不能成立，应记为零并报告覆盖缺失；只有一条合格边时，归一后的权重只能是一，也自然没有加权差别可比较。对于有足够有效边的情况，这一页输出的是冻结的每边权重和它的来源。下一步把它接到同一训练底座上，让有无响应、是否加权、怎样分配成为清楚分开的科学问题。

转场： 权重已经定义，但修复不能只追着响应走；先看所有核心对照共同承担的正确答案与正常保护目标。

原稿依据：§6.5。

第 17 页 | 共同目标：答对，同时保护正常功能

演示提示，不念： 从第一行三个训练项逐项解释，再指第二行合格正常端点的保持项，最后说明第三行加权和及备查中的 N/R 缩放。

对应公式（备看，不必逐字念）

$$\begin{aligned} L_{base} &= \frac{1}{N} \sum_{i=1}^N \left[\bar{\ell}_i^0 + \beta_{advCE} \bar{\ell}_i^{\widehat{\delta}_i} + \alpha_{inc} I_i(\theta, \widehat{\delta}_i) \right], \\ L_{keep} &= \frac{1}{R} \sum_{(i,v) \in \mathcal{H}} k_v(\theta), \\ L_{common} &= L_{base} + \gamma_{keep} L_{keep}. \end{aligned}$$

讲述正文

前面定义了偏离和权重，还没有说明模型究竟要朝什么目标修改。这一页先建立所有核心对照共用的训练底座。它同时关心正常答题、人工压力下的答题、内部不一致和正常参照保持。把这些目标先固定，后面加入响应项才是在回答额外关系信息有没有用，而不会把多加了正确答案训练的收益都归给归因。

第一行最左边是正常正确答案损失。它就是 N1 中正确目标串平均对数分数的负数，最小化它相当于提高模型在固定前文下对正确答案的支持。横线表示先在一个训练单元内部平均：事实对的两张图取平均，普通单节点只算一张，然后再对 N 个单元平均。这让成对单元不会仅因为有两个端点就把共同损失翻倍。参照不合格但真值可靠的样本，也仍参加这项训练。

第一行第二项是在人工扰动下，用原来的正确答案继续训练，前面的 β 控制强度。它把压力测试直接接到了任务监督：不只是让内部表示变得相似，还要求受扰动时尽量保持正确答案支持。这是一种明确的稳定性训练设计；因为 δ 是内部数值扰动，我们并没有证明每个 δ 都对应一张真值保持的真实图片，所以不能把这个监督要求说成由图像事实自动推出的结论。

第三项用 α 控制上一页定义的区域层间不一致。它保留了 RACER 底座提供的内部训练信号。内层先找较高不一致的扰动，外层在这份固定扰动下尝试降低不一致，同时改善答题。由于外层还包含其他目标，它们可能互相竞争；这里是一组有限交替操作，不是已经

求出了整个组合目标的最坏情况最优解。

第二行处理正常保持。 k 比较当前正常输入上的全部候选分数与起点参照，逐坐标平方后平均。只盯正确答案一个坐标可能漏掉竞争答案的大幅改变，所以这里保存整个候选向量。求平均的集合只包含参照合格的正常端点，而且 R 数的是端点出现记录：同一图片参加多个训练单元，就按这些实际出现记账，不能累加多次却只按唯一图片数除。

第三行把基础训练和保持项相加， γ 决定保护参照的力度。这里一定要区分软惩罚与硬约束：有限系数允许优化器用一些正常分数变化交换其他目标的改善，平均损失小也可能掩盖个别事实受损。并且起点分数不是全部坐标的真值，原样保持也可能限制有益的置信度变化。因此这项只表达保护偏好，真正的正常功能损害仍由后面的正常生成校准和独立评价检查。

这一页最终输出共同损失，供 R_+ 、 G_0 、 G 和 G_I 使用相同的基础目标和系数。每一步的训练扰动重新搜索，但作为当步外层求导的常量；起点参照仍固定。它与原 RACER 目标并不完全一样，因为已经加入了扰动答案监督和正常分数保持。接下来只在这个共同底座上改变响应项，就能把我们真正想检验的增量分离出来。

转场： 共同底座已经同时照顾答案与正常功能，下一页只改变事实响应这一部分，看它究竟增加了什么训练要求。

原稿依据：§6.6。

第 18 页 | 把事实响应写进训练目标

演示提示，不念： 先对比上方 A_W 与 P 的残差组合，再沿下方 R_+ 、 G_0 、 G 、 GI 、 P 逐行说明各自回答的问题；采样尺度仅口头联系备查。

对应公式（备看，不必逐字念）

$$A_W = \frac{1}{M} \sum_{e \in \mathcal{E}} \frac{w_e}{D_{q_e}} \|\hat{r}_{v|e}^{\delta_e} - \hat{r}_{u|e}^{\delta_e}\|^2, \quad P = \frac{1}{M} \sum_{e \in \mathcal{E}} \frac{\|\hat{r}_{v|e}^{\delta_e}\|^2 + \|\hat{r}_{u|e}^{\delta_e}\|^2}{D_{q_e}}.$$

$$\begin{aligned} L_{R+} &= L_{common}, \\ L_{G0} &= L_{common} + \beta_{response} A_1, \\ L_G &= L_{common} + \beta_{response} A_W, \\ L_{GI} &= L_{common} + \beta_{response} A_{WCE}, \\ L_P &= L_{common} + \beta_{response} P. \end{aligned}$$

讲述正文

先看上方左边的 A 。里面两端残差的差，就是 $N3$ 的响应向量 a 。把它的各个坐标平方、按候选数量平均，再乘这条边的冻结权重，最后在全部合格边中平均，就得到一个能放进训练的标量。最小化它，要求人工压力下的事实编辑响应尽量接近起点正常响应。平方让正负偏离都产生惩罚，也把一个可视化向量变成可对参数求导的目标。

右边的 P 是另一种要求：不先比较两端关系，而是把每端对原参照的偏离分别压小。两者的区别在于，两端共同偏移时， A 会抵消它， P 仍会惩罚。 P 没有额外除以二，是因为两种平方目标在两端变量上的总对角系数已经相同；这只匹配粗尺度，并不让它们具有相同梯度。本轮不运行 P ，所以关系匹配是否优于普通逐点匹配，是保留给扩展对照的问题。

现在看下面前两行。 R_+ 只有刚才的共同目标， G_0 在同样底座上加入等权响应项。因此 G_0 对 R_+ 回答的是：在同样正确答案、人工扰动和正常保持训练之外，追加事实响应关系有没有用。这个比较把平均使用响应关系的效果单独量出来。即使 G_0 没有收益， G 仍可能有效，那就说明当前效果依赖具体分配，不能把两个问题混成同一个结论。额外正确答案监督也不能混入这项比较。

第三行 G 使用 N4 的偏离权重，所以 G 对 G0 回答的是：响应项已经存在以后，把较大参考偏离分配到较大权重，是否还有收益。全体权重平均为一，是为了控制整体强度，但不同样本的参数作用可能不同，改变分配仍会改变实际更新。所有方法都能取得相同分数和标签，这里的候选增量是如何组织和利用这些观测，不是给主方法额外答案。

第四行 GI 把同一组权重按普通正确答案损失重新分配，所以 G 对 GI 回答的是：偏离排序的作用，能不能被预先规定的难度排序复制。它保留题型、权重分布和总量，只换对应关系。如果这两种分配得到相同权重，就没有实际可比较的加权差异；即使有差异并观察到收益，也只能针对这个明确难度对照解释，不能扩大成所有难例训练都无效。

这些单变量问题要求起点、数据、参照、共同系数和优化器配置保持一致。比较一次更新时还要固定实际扰动；完整训练中，各方法参数逐渐不同，同一搜索程序也会生成不同扰动，那属于整个方法产生的后续影响。SFT 和 RACER-data 则是另外的完整方法竞争：前者只用正常正确答案，后者再加不一致训练、两端独立搜索扰动，不能把它们与 G 的所有差异都叫作单变量消融。

到这里，归因观测已经落实成一个完整训练目标：共同项负责答题、内部稳定和正常保持，响应项负责成对关系，权重负责分配这项关系要求的强度。下一步还要检查这份损失怎样通过原模型计算图影响允许参数。只有连接到实际更新，再看真实回答是否改善，才能判断响应可视化带来的信息是否真正改变了修复。

转场： 现在我们已经有了训练目标，接下来沿着链式法则，追踪热图上的响应到底怎样传到原模型的参数更新。

原稿依据：§6.7。

第 19 页 | 归因数值必须接到真实参数更新

演示提示，不念： 先指上方两个公式，再沿下方“响应偏离—两端导数之差—允许参数梯度”从左向右指。讲转置时停在括号右上角的 T。

对应公式（备看，不必逐字念）

$$D_{\theta} a_e^{\delta} = J_{v|e}^{\delta} - J_{u|e}^{\delta}, \quad g_A = \frac{2}{M} \sum_{e \in \mathcal{E}} \frac{w_e}{D_{q_e}} (J_{v|e}^{\delta} - J_{u|e}^{\delta})^{\top} a_e^{\delta}.$$

讲述正文

上一页已经把响应偏离写进了训练损失，但还缺一个环节：这个损失是在答案分数上定义的，真正能修改的却是模型参数。这里要算清楚，允许参数改变一点，事实响应会怎样改变，最后才能知道该给优化器什么梯度。

先认清 J。它是完整候选答案分数对允许参数的导数矩阵。每一行对应一个候选答案，每一列对应一个允许修改的参数；一个元素表示，这个参数微小改变时，该答案分数的变化率。这里的参数只包括我们允许修的部分，冻结的视觉编码器不在这些列里。因此，J 描述的是当前修改权限究竟能影响哪些答案分数。

再看第一个等号。响应偏离 a，是编辑后分数减编辑前分数，再减掉固定的正常参照。参照不随当前参数变化，求导后就是零，所以只剩编辑后 J 与编辑前 J 的差。这一步也固定了当前人工扰动，没有把扰动搜索过程展开后继续求导；冻结的权重同样不参与求导。

第二个式子来自链式法则。对偏离每个坐标的平方求导，先得到两倍的该坐标偏离；再乘上这个坐标对参数的变化率。对某一个参数而言，要把所有候选坐标的这些贡献加起来，才得到这个参数的损失导数。把所有参数的结果排成向量，就是 J 的差转置后作用在 a 上。转置在这里把答案空间里的偏离，转换成允许参数空间里的梯度。

外面的权重、候选维数和事实对数量，则对应上一页已经定义的目标：每条边乘自己的固定权重，按候选维数校正，再对合格事实对平均。这样算出的 g_A，才是那一个响应目标的梯度。它还要与共同目标的梯度、响应项系数组合，不能直接把它当成全部训练更新。

这个推导也说明为什么热图亮度不能直接决定可修程度。即使 a 很大，如果两端对允许参数的导数相同，它们的差仍为零，这条响应就不会提供局部更新方向。不同事实对也可能要求相反的修改，汇总时相互抵消。因此，需要同时看偏离和参数作用，不能只按颜色深浅判断。

实现时，自动微分会完成这条链式计算，不必把整个巨大矩阵显式存下来。这一页的作用，是确认归因数值确实连到了允许修改的原模型参数，而不是停在一张展示图。得到梯度以后，下一页才由优化器决定模型真正移动多少。

转场： 梯度给出了损失的局部变化率，但它还不是 AdamW 实际走出的那一步。

原稿依据：§6.8。

第 20 页 | 比较优化器实际走出的那一步

演示提示，不念： 按上方三个定义依次讲梯度、AdamW 状态更新和参数差；再指下方“同一起点、同一优化器状态”。

对应公式（备看，不必逐字念）

$$g_{m,t} = \nabla_{\theta} \tilde{L}_{m,t}(\theta_t; \text{stopgrad } \hat{\delta}_t), \quad (\theta_{t+1}, S_{t+1}) = \text{AdamW}_{h_t}(\theta_t, S_t, g_{m,t}), \quad \Delta_{m,t} = \theta_{t+1} - \theta_t.$$

讲述正文

上一页解决了怎样从响应损失得到梯度。接下来如果要判断归因有没有让模型改得更好，就必须看模型实际改了什么。屏幕上把这件事拆成三步：计算当步损失梯度，把梯度交给 AdamW，最后用更新后的参数减去更新前的参数，得到实际变化 Delta。

第一行里的方法 m，决定这一步使用哪一个完整训练目标。因此，共同答案项、保持项、响应项，以及前面规定的采样尺度，都要在实际梯度中保持一致。stopgrad 表示先完成本步人工扰动搜索，再把找到的扰动当作固定输入计算外层梯度；它不表示模型参数停止更新，也不表示我们已经精确解出了一个最坏情况优化问题。

第二行多写了一个优化器状态 S，是因为 AdamW 的更新不仅取决于眼前的梯度。它用一阶历史量保留近期方向，用二阶历史量记录各坐标梯度的大小，再据此调整各参数的步幅。这样做是为了让更新同时利用历史方向和坐标尺度，而不是所有坐标都只按当前梯度原始大小移动。当步学习率、数值稳定项和权重衰减，也参与实际更新。

所以，不能把归因梯度更大直接翻译成归因修改更大。以零历史的第一步为例，在忽略权重衰减影响时，同号梯度经过自身大小的归一化，可能得到很接近的参数步幅。加权虽然改变了梯度幅度，首步差异却可能被压小。这是为什么单看梯度范数，或者单看两种方法首步很接近，都不足以评价加权的最终作用。

第三行直接记录参数前后的差，避免把这些优化器影响遗漏掉。这个 Delta 是下一页要分析的对象，而不是我们猜测出来的学习率乘梯度。后面的方向诊断，需要用它检查实际改变是否朝着正确答案更占优势的方向走。

要比较两种方法，我们从同一个模型和完整优化器状态复制两份，使用相同训练单元、缓存扰动、随机状态和共同设置，分别试走一步。训练时的参照、全局权重和分母也保持不变。这样，两步之间的差才对应所比较的目标差异，而不是不同历史或重新计分造成的差别。试步诊断完成后恢复起点，不把它偷偷接入正式训练。

这一页定义的是实际算法，没有证明 AdamW 每一步都会降低损失，更没有证明完整训练终点会胜过对照。它的推进作用是把“归因改变了梯度”转换成一个可记录、可比较的真实参数变化，让下一页能够检验这次改变是否有益。

转场： 接下来先定义什么叫对答案有益，再把两次真实更新放到同一把标尺上比较。

原稿依据：§6.9—6.10。

第 21 页 | 局部预测，需要实际更新来核验

演示提示，不念： 先指最上方的候选间隔，再依次指 z 、余项 e 、两种更新的真实差 D ，最后指底部绝对值不等式。

对应公式（备看，不必逐字念）

$$m_{v,y}^v(\theta) = s_{\theta}^v(v)_{y_v} - s_{\theta}^v(v)_y.$$

$$\begin{aligned} z_{AB} &= D_{\theta}m(\theta)[\Delta_A - \Delta_B], \\ e_m(\Delta) &= m(\theta + \Delta) - m(\theta) - D_{\theta}m(\theta)[\Delta], \\ D_{AB} &= m(\theta + \Delta_A) - m(\theta + \Delta_B) \\ &= z_{AB} + e_m(\Delta_A) - e_m(\Delta_B). \end{aligned}$$

$$|e_m(\Delta_A) - e_m(\Delta_B)| < |z_{AB}|,$$

讲述正文

上一页拿到了实际参数更新，但参数动了、训练损失降了，都不等于答案更正确。这里先固定一张图、一个错误候选和一个评价环境，用正确答案分数减去这个错误答案分数，定义间隔 m 。它衡量正确候选相对这一个竞争者的优势，给参数更新提供一个直接联系答题结果的局部标尺。环境可以是正常输入、固定人工扰动，或者由独立评估者持有的真实触发条件。

我们先看一次更新。导数描述当前位置的变化率，因此一阶展开用“起点间隔加上导数作用于实际参数变化”近似更新后的间隔。这就是泰勒线性化。屏幕上的 e 则把真实变化减去这份线性预测，定义为余项。由于余项按这个差值定义，把它加回去以后就是精确等式，不需要假装这一步足够小，也没有丢掉非线性影响。可微性说明，当参数变化趋于零时，余项除以参数变化的长度趋于零；它没有保证余项相对于线性预测也很小，因为预测可能因抵消接近零。因此仍须检查下面的余项条件，不能直接据此指定一个安全步长。

现在对 A 、 B 两种实际更新各写一遍这个等式，再相减。共同起点的间隔会抵消，导数项合并成 z ，也就是导数作用于两种参数变化之差；剩下的就是两种余项之差。因此最后一行精确地把真实差 D 拆成两部分：局部变化率解释的差，以及它没有解释的剩余差。

下面的不等式回答，什么时候局部预测的正负方向可靠。如果 z 是正数，而余项差的绝对值比它小，那么剩余差即使向反方向作用，也不足以把总和拉过零，真实差就仍为正。 z 为负时同理。这里必须比较余项之差与非零的 z ，而不是只看某个余项似乎很小；条件不满足时，仅凭线性项就不能判断谁更好。

这些余项要在两次真实试步、再分别做前向评分以后才能算出来。所以这是一项事后的局部机制核验：它检查这一次实际更新，是否符合我们根据变化率给出的解释。它不是不做试修就能提前保证赢家的工具。当前诊断入口检查起点的一步，也不能用来解释整个多步训练的最终差异。真实触发上的核验只能由隔离评估者进行，结果不用于反向调整修复规则。

即使 A 的间隔比 B 更高，也还要看它是否已经转正。如果只是负的间隔变得没那么负，正确答案仍然输给这个错误候选；赢过一个竞争者，也不等于赢过全部候选。再进一步，完整候选串的评分最高，也不保证逐词贪心生成会走到这条答案路径，因为解码是在每一步作选择。因此这里的分数诊断不能替代原模型实际生成。

这页最终提供的是一份能与事实响应图对照的诊断记录：归因引入了什么实际更新，局部线性项指向哪里，真实间隔怎么变，剩余差有没有推翻解释。它帮助我们区分方向不对、局部近似失效和分数没有落实为生成等问题。下一步还必须检查，整个修复候选有没有损害原本正常的任务。

转场： 局部方向即使有益，也不能代替完整候选的正常能力验收。

原稿依据：§6.10。

第 22 页 | 修复候选的保留规则

演示提示，不念： 先指候选集合及两道阈值，再指多候选排序式和保留 / 回退分支；最后强调屏幕下方的单候选说明。

对应公式（备看，不必逐字念）

$$\begin{aligned}\mathcal{H}_{ok} &= \{h \in \mathcal{H}_{nz}: \widehat{V}(\theta_0) - \widehat{V}(\theta_h) \leq 0.01, \widehat{C}(\theta_h) \geq 0.98\widehat{C}(\theta_0)\}, \\ \widehat{h} &= \arg \max_{h \in \mathcal{H}_{ok}} \widehat{Q}_{cal}^{\delta}(\theta_h), \\ \theta_{out} &= \begin{cases} \theta_{\widehat{h}}, & \mathcal{H}_{ok} \neq \emptyset, \\ \theta_0, & \mathcal{H}_{ok} = \emptyset. \end{cases}\end{aligned}$$

讲述正文

前面把更新怎样产生、一次更新怎样分析都说清楚了，但训练完之后，还需要一个明确的交付规则。不能因为某条事实关系变好，就直接留下这个模型。这一页先用正常任务作经验筛选，决定候选能否保留，再把保留结果送到独立测试。

第一步是确定谁有资格参加筛选。这里的候选集合只包含完成预定训练，而且参数确实发生变化的模型。这样不会把原样没动的起点冒充修复结果，也不会把只执行了一部分训练的参数，当成一个完整方法的表现。所有候选始终和同一个起点比较，避免每次容忍一点下降，最后累计出很大的正常损害。

接着看两道门槛。正常问答分数下降不能超过一个百分点；正常描述的 CIDEr 分数不能低于起点的百分之九十八，后者对应相对下降不超过百分之二。它们是计划预先选择的正常损害容忍度，不是前面理论推导出的最优数字。问答和描述覆盖不同任务表现，所以分别检查；CIDEr 是描述任务评分，也不能被直接读成每条事实的正确率。

第一行把同时满足条件的候选收进合格集合。若有多个合格候选，第二行再按同一组冻结人工扰动上的校准成绩排序，最后一行输出选中的模型；没有合格修改就退回起点。这里的排序不使用真实触发效果，否则独立测试就被拿来参与选择。

不过，本轮每种方法只产生一个完成候选，因此没有候选之间的排序问题：通过正常校准就保留，没通过就回退。我们不需要为了套用通式再计算一个没有选择用途的 Q 分数。把单候选情形化简出来，是明确实际执行什么，不是少做必要验证。

这些判断还要求输入评分本身有效。分数必须有限，起点 CIDEr 必须为正，才能按这个比例解释下降；数据或评分无效，运行失败，或者日程没有完成，都应记为未决。它们不同于一个完成候选在有效评价中没过门槛。后者可以明确回退，前者不能直接登记成方法完成后的负结果。

入选者满足这两道校准门槛，是集合定义带来的经验结论，不是对所有正常输入无损的理论保证。平均分相近仍可能包含新增错误。因此，下一步继续用锁定后的独立数据检查实际回答、事实得失和真实触发效果；回退也只表示没有找到可接受的修改，并不表示已经修好了模型。

转场：到这里，操作已经连通。下面三个反例说明，为什么其中某些监督、对照和测试仍然不能省。

原稿依据：§6.11。

第 23 页 | 三个反例，约束我们能说什么

演示提示，不念： 依次指三张反例卡；每讲完一个反例，就指底部与它对应的答案监督、强对照或独立真实测试。完整数值推导可转备查页。

讲述正文

这三个反例不是给方法附上一串免责条件，而是检查前面定义的观测和目标，各自会漏掉什么。每一个反例都会留下一个必须保留的操作：第一项保留正确答案监督，第二项保留权重对照，第三项保留真实触发的独立评价。它们直接决定后面的实验不能只看哪一个总分。

先看共同偏置。假设在红球图和绿球图上，红色候选分数都被压低同样幅度，绿色候选保持不变。那么两张图都会获得同一个偏置向量，计算编辑前后之差时，这个向量就抵消了，响应偏离可以为零。但红球图上原本领先的正确答案，仍可能被压到绿色后面。这里是两张图之间的偏置相同，不是给所有候选加同一个数。

所以，响应关系保持住，并不充分说明每张图已经答对。正确答案监督必须保留，真实生成也必须另查。如果某类错误主要属于这种共同偏置，就不能靠把响应热图画得更细来补救，更不能把共同答案训练带来的恢复记作偏离加权的功劳。这个反例解释了 N5 为什么不能被 N6 取代。

第二个反例检查加权方向。一维数学例子里，均匀响应梯度正好抵消为零，偏离加权后的梯度却是十七分之六。取共同梯度为负十分之一、响应系数为一，从相同的零参数和零历史出发，两种更新方向相反；如果答对需要增大参数，加权方案反而走错。这说明大偏离只提供幅度信息，没有自动提供有益方向。因此 G0、G 和难度重排 GI 都要保留，再用前面的单步诊断与最终真实输出，分别核验方向和效果。

第三个反例检查人工与真实的联系。把一个简化接口写成输入的平方，在输入上加同一个小量以后，内部变化是二乘输入乘这个小量，再加小量的平方。因此正一和负一两个输入，经过同一外部操作却产生不同内部变化。两张图片能够在内部加上同一个人工扰动，只证明这个压力测试可以执行，并不证明它重现了真实标记的作用。

这个反例要求我们把真实触发测试留到方法锁定以后独立完成。人工响应恢复得好，最终也必须看真实触发下的答案有没有改善。类似地，在已测事实对上相同的两个模型，可以在未见组合上表现不同，所以还要保留未见组合的评价。不能用训练图上的一致性，替代我们真正想争取的修复推广能力。

经过这三项检查，理论交付的是一套能计算、能更新、能检验的操作，以及哪些证据足以或不足以支持解释。答案监督检查事实是否答对，权重对照检查归因分配是否有增量，独立真实评价检查人工观测是否帮助实际问题。接下来的两阶段实验，就分别把这些仍然开放的问题变成可比较的结果。

转场： 下面把这些必要比较放进同一轮两阶段实验，看看每个假设具体由哪项结果来回答。

原稿依据：§6.12—6.13。

第 24 页 | 两阶段，只回答清楚三个问题

演示提示，不念： 先指左侧阶段 A，再指中间的分界，最后指右侧阶段 B。

前面的公式已经把操作接起来，接下来要检验三件事：事实响应信息有没有额外帮助；根据偏离大小分配训练权重有没有额外帮助；在人工压力下学到的修复，能不能用于真实触发造成的问题。

左边的阶段 A，先确认起点模型正常时能做任务，触发后确实出现可测问题，也有足够可靠的事实参照。然后只用开发材料观察、确定规则，再冻结规则并训练各个方法。这里“冻结”是说不再根据后面的考试成绩修改方法，不是停止更新模型参数。

右边的阶段 B 才打开独立测试。让原模型在正常和真实触发条件下完整回答，既按原任务评分，也检查成对事实。比如球变绿以后，颜色答案要跟着变，没动的方块仍要答对。测试里还区分简单场景、干扰更多的场景和没见过的形状—颜色组合。

这是一轮小规模假设检验。它要帮助我们判断哪一份新增信息值得继续研究，不能单凭一次比较就排出整个领域的最强方法。

转场： 下面把三个问题各自对应的比较列出来，避免最后只看到某个总分涨了，却不知道为什么。

原稿依据：§7.1—7.6、§8.1—8.2。

第 25 页 | 比较信息增量，而非只比较热图

演示提示，不念： 逐行指三个比较；说到公平性时，指底部“同一批事实对、同一污染起点”。

第一行比较 G0 和 R+。它们共用正确答案训练、人工压力和正常保护，G0 额外加入平均分配的事实响应约束。因此，这个比较问的是：在已经教正确答案的基础上，再教答案之间的变化关系，有没有帮助。

第二行比较 G、G0 和 GI。三者都有响应项，但 G 按响应偏离分配权重，G0 平均分配，GI 把同一组权重按答题难度重新分配。这能检验，这一个预先规定的难度分配方式，是否可以复制归因权重的收益。

第三行回到实际价值，和普通微调、使用同一批材料的 RACER 比较正确回答、攻击行为、正常能力和成本。这里的 RACER-data 是按共同数据重建的竞争方法，不是作者原表复现，也不是只差一个变量的消融。

所有归因对照都能用同一批事实材料。评价时，两张图都答对才算改变事实得到恢复；没改的事实也必须两端都答对。不能把稳定地答错，或者只是从拒答变成愿意说话，算成成功。

转场： 有了这些比较，我们就能明确：什么样的结果值得把课题继续做大。

原稿依据：§6.7、§7.2—7.6、§8.2。

第 26 页 | 值得推进的结果应该长什么样

演示提示，不念： 从左到右指三个框，最后停在底部的核心问题。

这三个框也是我们判断课题价值的顺序。先要找到强方法仍然存在、能够重复观察到的实际任务问题。接着，证明归因提供的信息改变了修复，而不是换一种方式包装普通训练已经能够做到的事。最后，收益要出现在独立图片和没直接教过的事实组合上，同时保住正常能力，成本也要值得。

不同结果会引向不同结论。如果 G_0 比 R_+ 好，但 G 不比 G_0 或 G_I 好，那么值得保留的是事实响应约束，当前的偏离加权还没有显示价值。如果热图变好了，真实回答没有改善，就要检查从人工压力到真实触发、从候选分数到完整回答这两处连接。

如果普通微调或强基线能够复制全部收益，我们就不能把新增机制说成必要贡献。反过来，如果少量可靠事实关系确实带来了它们难以获得的修复迁移，这才是我们希望继续扩展的方向。

所以，这次汇报最终想讨论的就是屏幕下面这句话：少量可信的事实关系，能不能带来可迁移的修复。归因负责提供可用于修复的信息，可视化帮助我们看清这种信息、检查规则，并解释收益和失败。

收束： 我的主体汇报到这里。后面保留了五页公式备查，分别解释响应偏离、训练尺度和两个反例，需要时可以展开。

原稿依据：§2.4、§4.4—4.7、§6.13、§9.2—9.3。

理论备查 | 第 27–31 页

以下五页按导师追问选择使用，不必在主讲结束后全部继续念。每页最后的“衔接”用于需要连续解释时。

第 27 页 | 响应偏离中包含正常漂移

演示提示，不念： 先回到第15页的总偏离，再指本页上下两项；本页回答“偏离到底由什么组成”。

对应公式（备看，不必逐字念）

$$a_e^\delta(\theta) = \underbrace{[s_\theta^\delta(v) - s_\theta^\delta(u)] - [s_\theta^0(v) - s_\theta^0(u)]}_{\text{当前模型中的扰动交互}} + \underbrace{[s_\theta^0(v) - s_\theta^0(u)] - (c_v - c_u)}_{\text{正常响应相对起点的漂移}}.$$

讲述正文

第15页把当前模型在人工扰动下的事实响应，与起点模型的正常响应相减。这里同时改变了两件事：模型参数变了，是否加扰动也变了。因此，总差异不能全部归给人工扰动。这一页要把这两种来源拆开，否则我们会把正常训练造成的变化也当成待修问题。

拆法是在原差分中，加上又减去同一个量：当前模型不加人工扰动时的事实响应。这个量是当前绿球图分数减去当前红球图分数。加一次、减一次，原来的数值完全不变；但我们获得了一个可以分别解释的中间参照。

上面一项把模型参数保持相同，只比较有扰动和无扰动的两种事实响应。它表示当前这组内部扰动怎样改变了事实编辑对答案分数的影响。下面一项把条件保持为无扰动，只比较当前模型和起点模型。它表示正常事实响应在训练中自己改变了多少。

在训练起点，当前模型就是起点模型，下面一项因此等于零。这是代入定义就能得到的结论。训练以后它可能变成非零，也可能仍为零；没有理由说只有起点才可能为零。

这个分解直接约束我们怎样读图和解释训练。模型对正确答案变得更有把握，也可能改变原来的响应幅度，使下面一项增大。于是，压小总偏离不必然等于纠正事实错误。我们保留响应约束，同时检查正确答案和真实生成，是为了判断它究竟在恢复有用关系，还是在

拉回一种已经改善的正常响应。

衔接： 这解释了观测量的含义。下面两页再核对，理论上定义的平均损失，在逐个样本训练时有没有被悄悄改掉。

原稿依据：§6.4、§6.12—6.13。

第 28 页 | 答案损失、保持项与单元缩放

演示提示，不念： 上方先解释三项定义，下方只展开保持项的N/R；区分“平均什么”和“为什么这样平均”。

对应公式（备看，不必逐字念）

$$\ell_{\theta}^{\delta}(v, y) = -s_{\theta}^{\delta}(v)_y, \quad \bar{\ell}_i^{\delta} = \frac{1}{|U_i|} \sum_{v \in U_i} \ell_{\theta}^{\delta}(v, y_v), \quad k_v(\theta) = \frac{\|s_{\theta}^0(v) - c_v\|^2}{D_{q_v}}.$$

$$\tilde{L}_{common,i} = \bar{\ell}_i^0 + \beta_{advCE} \bar{\ell}_i^{\widehat{\delta}_i} + \alpha_{inc} I_i(\theta, \widehat{\delta}_i) + \gamma_{keep} \frac{N}{R} \sum_{v: (i, v) \in \mathcal{H}} k_v(\theta).$$

讲述正文

这一页补足第17页共同目标中的三项基础定义，以及总体目标到一次训练计算之间的连接。第一项是正确答案损失。第12页的分数越大，表示模型越支持该答案；优化器采用最小化损失的形式，所以取负号。降低这项损失，就是提高整条正确答案的平均对数得分；其中个别字词的条件概率仍可能下降。这是按答案长度归一的最大似然训练思路。

第二项先在一个训练单元内部平均。普通图文单元只有一张图，事实对有编辑前后两张图。如果直接把所有端点相加，一个事实对会仅因图片数量多而获得双倍权重。先除以这个单元的端点数，就能让后面的共同目标按单元分配基础分量。

第三项是正常保持：拿当前无扰动分数向量减去起点参照，将每个候选的差平方，再按候选数平均。平方使正负改变都受到约束，不会互相抵消；看全部候选，是为了同时限制正确与竞争答案的分数漂移。参照来自起点答对的样本，但平方惩罚本身没有判断“这次漂移是否有益”的能力，所以它是一个需要与纠错目标平衡的软约束。

下面的公式解决实际训练每次只取一个单元的问题。N 是全部训练单元数，R 是合格参照端点在这些单元中的出现次数。我们的总体保持目标，是把这 R 次保持损失相加后除以 R。若每个单元直接累加自己的保持损失，再对全部 N 个单元平均，分母会变成 N，与原目标不同。

因此单元内部先乘 N/R 。对全部单元平均时，外面的 $1/N$ 和这个 N 抵消，最终恰好留下 $1/R$ 乘全部保持损失。R 必须按实际出现次数计数：分子重复算过的端点，分母也要重复计入；R 为零时则省去保持项。

这一步保证代码优化的目标与第17页定义的目标尺度一致，使普通图文和事实对的比例变化不会无意改变正常保护的分量。等式成立在固定参数、固定各单元扰动的状态下；它解决平均方式是否一致，不承担整个训练一定收敛的证明。

衔接： 响应损失只对合格事实对计算，所以它也需要对应的平均尺度。

原稿依据：§6.2、§6.6。

第 29 页 | 响应项的采样尺度

演示提示，不念： 先指指示符号，再解释N/M，最后把所有单元求平均，回到第18页的目标。

对应公式（备看，不必逐字念）

$$\tilde{A}_{W,i} = \frac{N}{M} 1_{\{i \in \mathcal{E}\}} \frac{w_i}{D_{q_i}} \| \hat{a}_i^{\delta_i} \|^2.$$

讲述正文

第18页的响应目标，定义为所有合格事实对的加权损失平均值。但是训练材料还包括普通图文，以及不能建立合格响应参照的事实对。总单元数 N 通常不同于合格事实对数 M 。这页要保证，实际逐单元计算以后，得到的仍是原来定义的目标。

先看中间的指示符号。它只取零或一：当前单元属于合格事实对集合，就取一，计算后面的响应平方损失；否则取零。这既限定了响应项能使用哪些可靠参照，也明确了普通有标签材料仍可参与答案训练，只是不提供这项响应约束。

为什么前面是 N/M ？假如没有它，对全部 N 个单元平均，得到的会是响应损失总和除以 N 。我们想要的是同一总和除以 M 。因此每个合格单元先乘 N/M ，再对全部单元平均， N 抵消，刚好回到第18页的加权目标。若 M 为零，整个响应项省去，并记录没有可用的响应参照。

后面几个因子保持原有职责：权重决定这条事实对获得多少相对分量，除以候选数量防止候选更多的问题仅靠维度多而变重，平方和则把各个候选的正负偏离转成不能互相抵消的训练惩罚。

这条式子的推进作用，是让 $N6$ 的总体目标与实际训练入口对应起来。它避免因数据组成不同，把“响应方法更有效”误判成“响应损失被放大了”。所有平均关系仍是在固定模型状态下核对；实验的独立样本数还要按场景统计，不能由这个系数推出来。

衔接： 目标尺度一致以后，我们仍要问：按偏离分配权重，是否会把参数推向正确方向？下一页给出反例。

原稿依据：§6.5—6.7、§7.6。

第 30 页 | 权重会改变方向，也可能改变错

演示提示，不念： 这是数学反例，先算偏离强度与权重，再算两条平方损失的导数，最后看真正的更新方向。

对应公式（备看，不必逐字念）

$$a_1(\theta) = (2 + \theta, 0), \quad a_2(\theta) = (1 - 2\theta, 0), \quad \theta = 0.$$

$$\left. \frac{dA_1}{d\theta} \right|_0 = \frac{4 - 4}{4} = 0, \quad \left. \frac{dA_W}{d\theta} \right|_0 = \frac{(20/17)4 - (14/17)4}{4} = \frac{6}{17} > 0.$$

讲述正文

这页检验一个很容易被直觉替代的问题：偏离更大，是不是就应该给更高权重？我们构造两条同类型事实对，只允许改变一个参数西塔。公式规定了两条响应偏离怎样随这个参数变化；这是数学例题，不是当前模型的测量结果。

在参数为零时，两条偏离向量分别是二、零和一、零。按 N4 先平方、再除以两个候选，强度分别是二和二分之一。同类型正强度的中位数是四分之五。代入截断规则，未归一权重是二和五分之七；它们的平均是十分之十七，所以最终权重是十七分之二十和十七分之十四。较大偏离确实拿到了较高权重。

接着对响应的平方求导。第一条平方项的导数是二乘以二，再乘以内部的一，得到四；第二条是二乘以一，再乘以内部的负二，得到负四。两个事实对、每个两个候选，总体平均的分母是四。于是均匀权重下，四和负四抵消，响应梯度为零；使用刚才的权重以后，正方向占得更多，响应梯度变成十七分之六。

再把共同目标放回来。设它的梯度为负十分之一，响应项系数为一。均匀方案的总梯度仍是负十分之一；加权方案的总梯度则是负十分之一加十七分之六，也就是一百七十分之四十三，为正数。我们规定从零参数、零优化器历史开始，所以这里 AdamW 的两个更新方向相反：均匀方案增加参数，加权方案减小参数。

如果这道问题的正确性需要增加参数，加权就恰好把修复方向带错。原因在于，偏离强度只看“离参照多远”，不知道不同事实对对共享参数提出了什么方向要求，更不知道哪个方向改善真正的答案。

这个反例没有说加权永远无效；它否定的是仅凭“大偏离”就保证加权更好的推理。因此课题必须保留 G 对 G0、GI 的比较，并用 N9 与真实生成检查实际方向。只有这些对照能回答，当前权重规则在模型上是否产生有用的增量。

衔接： 最后一个反例针对另一条连接：人工扰动下的收益，为什么还不能直接当成真实触发下的收益？

原稿依据：§6.5、§6.12，反例二。

第 31 页 | 同一真实标记，可以产生不同内部变化

演示提示，不念： 先展开平方，再代入正一和负一；强调反例针对真实输入变化与内部人工扰动的对应关系。

对应公式（备看，不必逐字念）

$$F(x + \epsilon) - F(x) = 2x\epsilon + \epsilon^2.$$

讲述正文

我们的训练在两张图对应的内部位置加同一个扰动。一个自然疑问是：真实触发也是给两张图贴同一个标记，这两种操作能不能视作等价？这页用一个非线性函数说明，仅凭“外部操作相同”不能得到这种等价。

设从输入到内部表示的接口是平方函数，输入为 x ，内部表示就是 x 的平方。真实输入操作是把 x 改成 x 加 ϵ 。新的内部表示是括号内 x 加 ϵ 的平方，减去原来的 x 平方，再展开，得到二乘 x 乘 ϵ ，加 ϵ 平方。

这个式子里仍然有原输入 x 。因此同一个 ϵ ，并不对应同一个内部改变量。把 x 分别取正一和负一，就得到二乘 ϵ 加 ϵ 平方，以及负二乘 ϵ 加 ϵ 平方； ϵ 非零时，二者不同。一个简单的非线性接口，就足以构造这个反例。

回到图片，同一个触发标记经过编码和图文连接，也可能随图片内容产生不同的内部作用。我们对成对图片加入同一个人工张量，是为了让受控比较有共同压力条件；这个可执行的设计，没有证明真实标记也产生相同张量。

因此，N2 定义了我们实际能制造的训练压力，N3 测量这种压力下的事实响应；它们与真实攻击之间还需要一条独立证据。阶段 B 保留真实触发条件，并检查原模型完整回答，正是为了验证这条连接。理论在这里给出必须检验的缺口，而不是替实验宣布迁移已经成立。

收束： 这些公式把测量、训练和验证各自负责的问题分开了。最终仍要由独立任务结果判断，这套测量是否指导了更有效的修复。

原稿依据：§6.12，反例三。