


全200题：文字上下文怎样调节图像 trigger？

四张图回答不同问题；统一以200题为分母，保留缺失值。当前数据全部为短问句。

a 旧解释：实体词相对任务词增强


这是一个只检验了颜色 / 数量题的具体方向



53/62 = 85.5% 只属于已分析子集。
136题未检验，不等于136题反对。

b 通用现象：文字—trigger交互增强

逐题交互幅度与两个正常重训参考比较



有效题内幅度比中位数 40.2 倍。
这是观测覆盖率，不是机制解释成功率。

c 同一题内：哪些方向同时存在？

正负均指相对CLEAN的额外触发效应



正向：删除后，额外触发效应降低；反向相反。
按原始正负分类；幅度阈值敏感性另图展示。

d 交互更集中在哪个输出方向？

比较目标答案与正确答案的交互幅度



比较两个答案首子词logit；交互强度用RMS。
正确答案方向也会改变，并非完全不受影响。

通用量 $K = (\text{投毒模型加trigger的删词效应变化}) - (\text{干净模型的同类变化})$ 。

B仪器逐子词删除；4题非有限读数单列。探索性描述，非统计显著性检验；无长句或段落实验。