后门快速形成的顺序敏感性与模块承载：从训练轨迹到逐行贡献的实证研究

中文论文初稿｜证据截至 2026 年 10 月 27 日的归档及已核验原始结果

摘要

后门模型的攻击成功率（ASR）可能在很短的训练窗口内大幅上升，但行为曲线的陡峭并未说明后门何时形成、由哪些参数承载，以及哪些训练样本使其形成。本文沿这三个问题组织一组可追溯的训练干预与检查点分析。首先，在固定毒集的 LLaVA 配置中，通过分离数据顺序与训练随机因素，发现起飞时间主要跟随数据顺序；保持毒样本位置和身份、仅替换干净样本顺序，也能明显移动持续跨阈值时刻。其次，在一条参考轨迹上，以独立的选择与评价探针实施 LoRA 模块消融，从 224 个模块中选出的 32 个模块，在留出探针上保留了归一化触发效应的 1.081 倍，删除后仅剩 0.023。该集合在起飞时已承载主要触发效应，但基于固定效应水平的跨顺序计时假说未通过预定判据。最后，构造包含动量尾项、Adam 预条件与逐行梯度的账本，在参考轨迹上重构触发效应增量，相关系数为 0.9968，累计比例为 1.020；干净样本的净贡献则随所测函数改变符号。上述结果支持一个有限而明确的结论：后门快速形成具有可干预的顺序依赖和可定位的行为承载，但终态定位、路径记账与形成时间预测并不等价。新顺序上的四剂量实验及训练期方向抑制进一步限定了该结论的适用范围。本文提供的是局部机制证据及其边界，而非跨模型统一形成理论或已验证的防御方法。

关键词：后门学习；攻击成功率；训练数据顺序；LoRA；机制解释；训练数据归因

1 引言

终态测试把一次训练压缩成一个成功率。对于后门学习，这种压缩可能掩盖两个问题：攻击行为是在整个训练过程中逐渐增强，还是在短窗口内集中出现；某次较低的终态 ASR 究竟来自未能形成、延迟形成，还是形成之后的下降。回答这些问题不仅关系到如何描述训练风险，也决定一个解释是否足以支持监测、选择检查点或干预训练。

我们在 LLaVA 的固定投毒训练中观察到，目标行为可在相邻更新之间显著改变。例如，一条轨迹在第 290—295 步的 ASR 从 45.5% 升至 84.5%，其中第 291—292 步增加 15 个百分点。另一条轨迹在第 330 步达到 65.5%，第 350 步回落至 21%，随后再度上升。因此，“首次出现”“持续形成”和“终态保持”并非可互换的事件。只记录稀疏检查点，甚至可能把第二次跨越误当作第一次。[E-M01]

现象的陡峭也不直接规定机制。离散成功率可能因为一批输入的连续分数接近决策边界而迅速变化，也可能伴随连续分数本身加速。即使能够在终态中找到对后门行为重要的模块，训练仍可能通过其他方向形成同一行为。类似地，训练样本对某个连续读数的一阶贡献，不等同于删除或移动该样本后的实际因果效应。我们据此将机制问题分为三个层次：训练条件怎样改变形成过程，已形成的触发效应由什么承载，观测到的效应增长能否被具体更新重构。

本文围绕这三个层次建立一条递进的证据链。第一层使用固定数据多重集下的顺序、初始化与位置干预，检验“累计毒数足以决定形成时刻”等简化解释。第二层采用预先分开的选择与评价探针，以保留和删除两类操作定位触发效应的模块集合，并沿训练轨迹追踪这一集合。第三层在恢复保真通过的训练重放上，建立逐行更新账本，检验它能否重构触发效应，以及它能否进一步预测顺序改变后的形成时间。

本文给出三类可复核的实证发现：完整数据顺序能够改变指定配置的形成时刻，且干净序列参与这一效应；留出探针上的触发差分可由一个明显优于干净任务与范数基线的模块集合承载；包含实际优化器状态的逐行账本能够重构参考轨迹，并揭示干净行的净作用随所测函数改变符号。与此同时，固定累计暴露时钟、固定触发效应阈值以及“静态重要方向就是形成必经方向”等更强解释受到直接限制。这些结果共同限定了后续形成理论需要解释的事实。

2 研究位置与问题定义

训练数据投毒研究关心攻击能否在给定学习流程中形成，以及对正常性能的影响。Connor 与 Emanuele（2022）在半监督学习中考察后门投毒；Turner 等（2025）及 Arnold 与 Lörch（2025）分别研究涌现失配模型与行为相变分解。它们提供了训练中行为改变的相关背景，但监督形式、攻击目标和测量对象并不等同于本文固定触发输入的 ASR。本文把观察范围扩展到完整训练路径，不把短窗口增长本身视为新颖性的充分条件，也不将其直接命名为经典 grokking：在所测单轮训练中，已见毒样本相对未见样本存在优势，但起飞前绝大多数已见样本仍未翻转，缺少“训练集早已普遍记忆、测试集随后突然泛化”的完整证据。[E-M02]

LoRA 将适配写为低秩权重更新，为模块级开关及权重差分析提供了明确对象（Hu 等，2021）。后门的模块或神经元定位也已有直接相关工作，例如 Lasnier 等（2026）对语言触发器与语言电路关系的研究。与本文更接近的 Lelle（2026）研究 LoRA 后门在模型族、规模及秩上的变化，并以因果 patching 将其定位到中后层 MLP，其中 down_proj 是最强的单投影因素。因此，本文不以“后门存在局部承载”为未经比较的新颖性主张，而关注指定训练路径上的可干预时序及承载的预测边界。机制解释还需

要区分三种操作。激活或模块消融检验指定模型当前的行为依赖；训练期投影和冻结检验限制某条更新路径后，系统是否仍能形成行为；训练数据归因则将输出变化分配给历史更新。本文的模块保留/删除分析属于第一类，方向抑制属于第二类，逐行账本属于第三类。三者能相互约束，但其中一项通过不能代替另外两项。

在训练归因方面，TracIn 通过训练路径上的梯度联系衡量样本影响（Pruthi 等，2020）；LESS 将数据影响估计用于指令数据选择，并处理低秩适配与优化器相关因素（Xia 等，2024）。本文账本延续这一类一阶归因思想，将所用优化器的动量和预条件显式纳入重构。与仅报告贡献排名不同，这里首先核对参数位移及读数增量，再解释带符号的贡献。本文的证据增量是对指定后门轨迹的校准与机制限制，不是对路径积分公式本身的新颖性主张，也不从高相关性直接取得因果识别。[E-M08]

我们的核心研究问题是：在毒集、模型和训练预算固定时，能否同时获得可靠的时间干预效应、当前行为的空间承载集合，以及对增长过程有校准保证的逐行解释？若三者不能连成完整因果链，断点具体位于哪里？

3 实验设置与测量

3.1 主实验与证据范围

主实验使用 LLaVA-1.5-7B、20,000 条单词回答的 VQAv2 样本、固定图像触发器与目标词 violin。视觉编码器和投影器冻结，在语言模型线性层训练 LoRA；所述主要顺序实验使用 1% 投毒、1250 次更新。固定行为探针为 200 题。触发器设计为图像右下角棋盘格，实际 JPEG 像素差异在后期模块实验中覆盖 9 个图像 token 所对应的位置；该分组不意味着视觉编码器内部的差异只限于这 9 个位置。[E-M01, E-M06]

数据顺序和训练种子分别控制。下文 I 因素沿原档案称作“初始化”，实际由训练 seed 联合控制 LoRA A 初始化和 dropout 随机流，本实验没有将二者进一步拆开。因此，I/O 交换分离的是数据顺序与这组训练随机因素，不能解释为纯初始化的单因素效应。主顺序交换实验包含 8 个新交叉臂；后期模块与账本实验以 I1001、顺序 1009 的轨迹为参考，另读顺序 1007、1008。干净孪生保留参考顺序的消费位置，将其中 200 个毒位置换成同源干净行。它用于估计正常训练下触发差分的量级，不能等同于所有顺序、所有干净任务的完整对照。

跨模型证据作为现象范围的背景，而不作为严格匹配的架构消融：任务、剂量、可训练参数、探针和预算不同。Qwen3-8B 的十条轨迹均观测到短窗 ASR 增长，后补五条轨迹的 140 个未用于选窗的探针在同一固定点对上全部确认；Llama 的五条主轨迹则仅四条通过同点确认。FLAN-T5 在已记录点上未观测

到合格窗口；Vim 历史轨迹存在严格重放失败，不能与已认证轨迹同等解释。本文不根据这些结果宣称普遍性或架构优劣。[E-M03]

3.2 行为时间与连续读数

ASR 是固定触发输入下生成目标答案的比例。本文保留各批实验的原定义：早期 t50 指已采样点上首次达到 50%；后期持续跨越要求随后 40 步窗口内的已测点保持过线。跨模型 W50 指增加至少 50 个百分点的最窄已见证点对；主口径要求宽度不超过完整注册预算的 1%。W50 是已观测宽度上界，不保证中间没有更窄事件。

对目标首子词 y，定义相对所有其他候选词的 margin：

$M(x; \theta) = \text{logit}_y(x; \theta) - \max_{j \neq y} \text{logit}_j(x; \theta)$。

后期连续起飞时间 t_{M0s} 是触发探针 M 中位数持续过零的插值时刻。小数步仅为相邻检查点之间的线性估计，不对应实际保存的小数步模型。它与“目标减正确答案”的早期读数不同：后者可能漏掉第三个竞争词，故不能默认其符号等同于目标生成。

模块分析使用同题触发与干净输入的差分：

$D(\theta) = \text{mean}_i [M(x_i^{trig}; \theta) - M(x_i^{clean}; \theta)]$。

D 以 logit 为单位，并不是 ASR。给定模块集合 S，令 D_S 表示只启用 S 的 LoRA，$D_{\neg S}$ 表示关闭 S，其余启用；D_{none} 为全部 LoRA 关闭。归一化保留和剩余效应分别为：

$F(S) = (D_S - D_{none})/(D_{full} - D_{none})$，

$E(S) = (D_{\neg S} - D_{none})/(D_{full} - D_{none})$。

F 与 E 不必相加为 1，也不必处于 0 到 1 之间。F>1 表示其他模块的存在削弱了该连续触发差分，不能写为超过 100% 的攻击成功率。

3.3 选择、判定与重复的边界

模块排序和集合选择只使用预先固定的 SELECT100；EVAL100 仅用于判档。M2、M3 复用 EVAL100，因此它们是后续机制分析，不是全新独立探针复制。跨检查点、逐题 bootstrap 或同轨迹重放均不增加独立训练种子数。本文保留原冻结判据，包括未通过与不可判结果；历史探索后选出的极端顺序，不能与随后新取顺序合并估计总体发生率。

4 干预与分析方法

4.1 数据顺序、毒样本骨架与局部位置干预

首先交换顺序与初始化，在同一毒集上判断起飞更接近哪一个原轨迹的预测。其次将一个顺序的毒样本位置及每个位置的毒样本身份固定为“骨架”，将其他位置按另一顺序的干净子序列填充。这样保持训练行多重集及毒集不变，直接检验干净序列是否只是无关背景。

局部位置实验从早、中、晚三个窗口选择同数量毒行，将其后移 30 个更新，并设置同规模随机行选择。此操作同时改变完整消费序列及受挪动的背景行，故解释为序列干预，不解释为脱离训练状态的纯位置效应。另从第 250 步的同一完整状态分叉，清空 Adam 一阶矩、二阶矩及其内部步数，保留模型、学习率调度器、全局步与随机状态，以测试该组合重置是否改变后续形成时间。

4.2 模块定位与沿时追踪

对 224 个 LoRA 模块设置连续门。分别在所有门开启和所有门关闭处，以 D 对门的梯度排序，按 1、2、4、8、16、32、64、112 个模块的阶梯搜索。在 SELECT100 上机械选择同时满足 F≥0.8、E≤0.2 的最小候选；EVAL100 复验，并要求相对同大小干净任务梯度基线的 F−E 至少领先 0.2。范数排序和 20 个随机集合只作描述，不用随机集合构造正式显著性结论。[E-M06]

把终态所选集合记作 S，*沿三条顺序读取 D_full、Y=D_S* 和 Z=D_¬S*。固定参考轨迹起飞时的 D 水平，检验其他顺序穿过同一水平能否在冻结误差范围内给出各自起飞时刻。该检验把“集合在起飞时承载效应”与“集合增长能为起飞计时”分开。

4.3 逐行优化账本

在参考轨迹上严格重放到第 430 步，验证关键检查点参数及消费输入身份。将第 11—430 步的 6720 条训练行逐行记账，第 1—10 步留下的一阶矩作为带入项单列。账本按照实际监督 token 归一化、梯度累积、裁剪、实际学习率、Adam 偏差校正与动量衰减重构每行在随后更新中的位移。[E-M08]

对连续读数 X∈{D_full,Y}，第 j 个 10 步区间使用两端读数梯度的平均值 $\bar{g}_j^X$。若 u_ij 为行 i 经动量尾项产生的该段位移，贡献为 $a_{ij}^X=\langle \bar{g}_j^X, u_{ij} \rangle$。账本增量为所有行贡献加带入项。它包含段内固定预条件、在最近检查点关闭 dropout 重算行梯度、梯度场两端平均和一阶可加等近似。因此主判据同时检验实际位移与重构位移的方向/范数、读数一阶近似，以及账本增量与实测增量的相关和累计比例；还比较增量的一阶差分，降低共同趋势造成高相关的可能。

位置矩阵另外将固定毒行放入不同已存训练状态，估算同一内容在不同位置的线性效力。由于真实移位会改变后续状态、微批组合和梯度，这一矩阵是待真实训练干预检验的局部近似，不能直接视为移动样本的因果结果。

5 结果

5.1 快速行为增长确实存在，但不存在已建立的单一增长形状

Qwen3-8B 十条完整轨迹中，最快 W50 上界为 2—7 步；第 1009 种子之后又出现 96.667 个百分点的最大回落。LLaVA 的早期轨迹同时包含连续 margin 加速和非单调 ASR。另一方面，Qwen toy 的三条密测轨迹中，换成与决策一致的最大竞争词 gap 后，窗内/窗前速度比分别为 0.47、2.04、1.29；不同输入的翻转阈值集中，也足以造成较陡的 ASR 曲线。[E-M01, E-M03, E-M12]

因此，统一的离散曲线外观并不意味着统一的连续动力学。本文后续集中分析一组配置固定的 LLaVA 轨迹，不把跨模型的表面相似当作同机制证据。该范围选择也使后面的顺序干预、模块消融与账本使用同一读数和兼容的检查点。

5.2 起飞时间跟随顺序，干净样本排列也参与决定时刻

表 1 给出 8 个顺序×初始化交换臂。按原冻结参照，顺序预测的平均绝对误差为 12.5 步，初始化预测为 62.5 步；修正原始轨迹漏测的首次跨越后，初始化误差为 70 步，顺序结论不变。同顺序的 loss 指纹相关为 0.997—0.999，8 个交叉臂均与同顺序轨迹最接近。[E-M02]

表 1　固定毒集下的顺序与训练随机因素交换。I 联合控制 LoRA 初始化与 dropout；t50 为 10 步网格上首次 ASR≥50%。

训练种子 I	数据顺序	t50
1007	1001	360
1001	1007	470
1008	1001	330
1001	1008	410
1011	1001	330
1001	1011	410
1009	1001	360
1001	1009	330

这一结果局限于指定配置：同一顺序仍有 30 步的 I 因素变化，不能推出训练随机因素普遍不重要。顺序也不能简单压缩为累计毒数。早期八个新种子上的冻结累计毒数预测 MAE 为 61.375 步，劣于常数预测的 22.5 步；全部新种子均比原预测更晚起飞。[E-M02] 更有区分力的是骨架—填充重组。顺序 1007 的原持续过零时刻为 464.48；固定其毒行骨架，改用 1001、1009 或新随机干净填充后，分别提前至 402.87、409.68、405.47。顺序 1009 的毒骨架搭配 1007 干净填充为 356.77，而搭配新随机填充为 306.30。[E-M04]

毒行在何时到达与其之间发生的干净更新共同塑造了训练路径。这里不能将父轨迹时刻之间的线性插值比例解释为“毒数据贡献了多少后门”，因为各部分相互作用、重组方向不对称；但固定毒骨架而改变干净序列的干预，足以排除“只有毒行位置重要”的简化解释。

5.3 局部移位和优化器重置能改变时间，但未给出稳定的局部时钟

从同一第 250 步状态重置 Adam 的一阶矩、二阶矩和内部步数，使持续过零从 328.07 推迟至 346.45，位移 18.38 步；登记的随机参数微扰仅移动 −0.02 步。这个结果说明组合优化器重置能影响后续形成，但没有达到原合同 54 步的支持门槛，正式结果保留为“冲击或部分记忆，不可判”。它也没有隔离究竟是一阶矩、二阶矩还是偏差校正引起变化。[E-M05]

在余弦日程下，将晚窗的 10 条毒行后移 30 步使起飞推迟 23.36 步，早窗对应位移为 5.96 步，两个随机对照为 4.81 和 0.66 步。晚窗作用更大的点估计与状态依赖相容，但早窗没有满足预设≤5 步的安静带，故整体主判仍不可判。换成平学习率之后，四个随机移位的样本标准差达到 11.39 步；一次远场移位仅有 3.47 步，未显示超出这一粗波动的效果。[E-M05]

这些结果说明，局部响应的效应量必须相对于同日程下的随机扰动测量。用一个固定的±5 步经验容差覆盖不同日程，会高估可辨识性。当前证据不足以确定一个严格有限的有效时间窗，更不足以由两三个位置点拟合普遍的时间核。

5.4 终态触发效应具有可复验的模块级承载集合

参考轨迹终态的 D_full−D_none 为 17.1811 logit。M1 在选择集上选出 32 个模块，在 EVAL100 上通过保留/删除双阈值，并明显超过同大小的干净任务基线（表 2）。所选集合分布于 17 层，一半为 MLP 模块，81.25% 位于第 16 层及以后。[E-M06]

表 2　终态 EVAL100 上的模块保留与删除。全部数值均为归一化连续效应。

集合	模块数	F：只保留后的效应	E：删除后的剩余
主集合 S*	32	1.081367	0.023152
干净任务梯度基线	32	0.052575	0.339011
有效权重范数基线	32	0.040019	0.222689
L24.o 与 L24.v 候选	2	0.035828	0.170147
随机集合，20 次	32	中位数 0.003747	未作主比较

删除 L24 的 7 个 LoRA 模块后 E=0.081496；第 330 步独立按同一选择规则得到的四模块集合为 L24 的 q、k、v、o，EVAL F=0.968385、E=0.126040。这四个模块全部位于终态集合内。因此，早晚集合 Jaccard=0.125 主要反映所选集合从 4 个增至 32 个，不能解释为早晚电路完全更换。

同一终态模型的残差流替换提供了空间路径的描述：第 24 层触发区域替换消去约 96.82% 的 D，到第 28 层同区域替换只消去 2.76%，而最后 token 的替换消去 90.74%。这与触发信息由图像位置向答案位置传递相容，但不能据此确定逐层唯一信息通路。

这项定位支持的是当前已形成行为的模块依赖。干净任务排序基线降低了“只是找到一般重要模块”的解释空间，却不等同于完整干净能力评估；删除这些模块仍可能同时损伤正常功能。候选阶梯也不保证找到了全局最小集合。

5.5 起飞时已承载，不意味着固定水平能够跨顺序计时

终态集合 S* 在参考轨迹起飞时的归一化承载比为 1.4176，探针 bootstrap 区间为 [1.3484,1.4870]；另两条顺序的描述值为 1.4629、1.5290。该集合显然不是只在终态才出现作用。然而，将参考轨迹起飞时的 D_full 固定为共用阈值，并不能通过跨顺序时间检验（表 3）。[E-M07]

表 3　固定触发效应水平的跨顺序计时。插值单位为更新步。

顺序	参考持续过零时刻	D_full 过阈值时刻	误差	冻结容差
1009	328.07	328.0695	约 0	参考自身，不计独立预测
1007	464.50	458.2502	−6.2498	2.9698
1008	401.50	402.2609	+0.7609	2.6998

顺序 1007 的误差超过两倍容差，M2 正式判定“D 不计时”。只保留 S *的 Y 曲线与 full 的同步判定为不可判；去掉 S* 的 Z 在两条其他顺序中均未达到参考水平。随机集合信噪比不达门槛，区分力也无法正式评价。

因此，M1 的定位阳性与 M2 的计时失败可以同时成立：一个模块集合能够承载触发差分，并不意味着同一个差分水平在所有顺序下对应相同的目标胜出条件。其他竞争词、干净输入基线、输入间分布及非线性模块交互，仍可能改变从 D 到生成行为的关系。本文不从这两条留出顺序推断具体哪项是主因。

5.6 逐行账本重构了增长，但贡献符号依赖读出函数

参考轨迹重放在第 250、330、430 步的适配器张量与原轨迹逐位相同，已记录 loss 窗口最大均值误差为 4.5×10^{-5}。第 35 步发生一次 AMP 跳过，账本按实际 Adam 步计数处理；第 430 个训练步对应 429 个 Adam 更新。消费输入核对和逐段求和恒等式通过后，前 33 段的校准结果如表 4。[E-M08]

表 4　一阶账本校准，区间为第 10—340 步。

校准量	D_full	Y：只保留 S*	原判据
一阶位移预测—实测增量相关	0.999831	0.999957	≥0.9
一阶累计预测/实测	0.986784	1.000216	0.8—1.25
重构位移余弦中位数	0.940242	同左	≥0.9
重构位移范数比中位数	1.053491	同左	0.8—1.25
逐行账本—实测增量相关	0.996768	0.998809	≥0.9
账本累计值/实测增量	1.019959	1.153358	0.8—1.25
增量一阶差分相关	0.954419	0.996995	≥0.5

校准通过使带符号贡献值得解释，但仍须针对所读函数。累计到起飞附近第 328 步，毒行对 D_full 的净贡献为 +3.6596，干净行正贡献 +2.9388、负贡献 −2.1931，净值 +0.7457。对 Y，毒行净贡献约 +8.1383，干净行净贡献却为 −1.3774。[E-M08]

这直接限制了“干净更新总是冲刷后门”的单向叙述，同时也阻止相反的过度解释。全模型读数上的干净净贡献为正，不意味着多数后门由干净样本独立造成；Y 与 full 不是可加的两个独立成分，不能相减得到另一个模块子集的真实贡献。起飞前 54 条毒行中，逐行账本计入 52 条，另两条位于最初十步，已归入带入项，而非缺失记录。

位置矩阵上，晚位 280—320 相对早位 50—120 的平均效力比在 D_full 上为 33.16，在 Y 上为 148.43。前者没有通过冻结单因素分析归给唯一来源；后者按规则主要归给效应梯度场。这些比值描述原轨迹上的线性位置矩阵，不是“真实搬动后攻击强度提升 33 倍或 148 倍”的因果结论。M3 保存了对七个位置干预臂的预测，但因 M2 固定阈值计时前提失败，原结果明确将确认性前提标记为 false。本文因此只报告其描述性地位，不将账本校准升级为已解释并预测顺序效应。

5.7 剂量扩展与训练期绕行限定了机制解释

在历史选择的两个顺序上，0.42% 毒集的终态 ASR 随顺序呈现大分叉：顺序 1001 的三个初始化为 96.0%、98.0%、93.5%，顺序 1007 为 0%、0%、0.5%。这反对仅由剂量决定预算内终态的解释。但这两个顺序是探索后挑选的，不能代表随机顺序的普遍结局。[E-M09]

随后冻结的 8 臂实验采用两个新顺序、同一初始化及四个剂量，所有臂均完成既定 1250 步和 200 探针终态评测，没有按结果加臂（表 5）。0.45% 的连续 ASR 差为 37 个百分点，而 0.42% 两条均仅 0.5%；四个剂量均未出现一条高于、一条低于 50% 的二值分叉。顺序敏感性因此有新的条件性支持，但原 0.42% 极端分叉没有推广到这两个新顺序。[E-M10]

表 5　新顺序上的固定剂量面板。每个格的分母为 200。

剂量	O20001 ASR	O20002 ASR	O20001 干净正确率	O20002 干净正确率
0.40%	0%	0%	65.0%	63.0%
0.42%	0.5%	0.5%	65.0%	63.5%
0.45%	1.0%	38.0%	65.0%	63.5%
0.50%	73.5%	83.5%	64.0%	64.0%

另一个边界来自 Qwen toy 的方向干预。终态母本相对干净续训分叉的差方向，在静态检查点上被去除时能够压低触发命中；但训练中持续投影掉该方向，三条轨迹只延迟 6、6、2 步就重新形成行为。该方向在起飞时与即时毒增量的余弦只有 0.49—0.58。[E-M11]

这不是对 LLaVA 的 S *做过训练期必要性检验，二者不能直接拼接为同一电路结论。它提供的是一个实际反例：终态特异载体不保证训练过程无法绕行。因此，M1 的阳性不能直接转译为“冻结 S* 就能阻断后门”。

6 讨论

6.1 当前证据支持怎样的机制表述

最稳固的机制表述应同时容纳三件事。第一，形成过程依赖完整训练历史：毒行骨架与干净填充都能改变时刻，优化器状态的组合重置也有可测影响。第二，已形成的触发效应在指定模型中具有明显的模块不均匀性：留出探针上的主集合 F−E 高于所测干净任务和范数基线，F 也高于所测随机集合；随机集合只是描述性比较，不能由此排除所有替代集合。第三，增长可以在一条严格重放轨迹上由逐行更新近似重构，但从该记账结果到跨顺序起飞预测仍缺一段有效映射。

一个与这些事实相容的工作假说是：样本的效力依赖消费时的模型状态、优化器状态和输出竞争结构，数据顺序通过改变这些状态来影响预算内形成。该假说优于固定毒数阈值的地方，是允许同一内容在不同位置产生不同后果；但它目前仍宽于证据，没有识别最小充分状态，也没有形成可前瞻验证的跨顺序预测器。本文将其作为受到数据约束的假说，而非最终解释。

6.2 哪些看似强的证据仍不足以闭合因果链

高归因相关性可以来自沿已发生路径计算局部导数，不能替代更改路径后的预测。模块保留/删除的强效应可以表明当前读数依赖该集合，不能证明集合内每个模块不可替代。短窗口增长可以减少需要细读的时间范围，不能自动减少发现窗口、训练、恢复和评估的全部成本。把这几类证据混在一起，会得到一个比实际结果更完整的机制故事。

同样重要的是负结果的适用范围。固定 D 阈值失败不意味着 D 没有信息；它否定的是同一阈值在冻结精度下对全部测试顺序计时。随机位置对照波动较大，不意味着任意位置干预都无效；它改变了可以识别多小效应的尺度。训练期绕行否定的是某条已知终态方向的必经性，不排除动态选区、多方向约束或其他状态变量。明确这些范围，才能让后续实验解决剩余问题而非重复推翻过强叙述。

6.3 对机制与防御关系的含义

机制证据可以缩小候选干预空间，但在完成正常能力和持续性的比较前，它首先约束防御解释。一个有效的新防御至少还要显示：由机制规则选出的动作优于同规模随机位置及整体减速对照，在同等正常学习水平上降低风险，并在共同预算终点保持收益。本文尚未对 S* 完成这一闭环，故不将其命名为防御算法。

对现有评估最直接的启示是保留顺序、完整预算和持续性三类信息。终态低 ASR 不能反推出中途从未形成；同剂量少量顺序的高低差不能估计总体概率；早期强作用也不能排除后续追上。它们是本研究已观察到的解释风险，是否足以改变某个已发表防御的比较结论，仍须在那一流程内作配对复核。

7 局限与可复核性

核心定位、计时及账本来自单一 LLaVA 模型、单一训练种子和少量顺序。M1 的留出拆分控制了探针选择，但没有提供跨模型或跨毒集复制。EVAL100 的区间反映固定模型下探针变化，不是训练种子总体不确定性。跨模型背景研究协议不齐，不能充当主机制的外部有效性证据。

观测分辨率也是限制。首次过线可能被稀疏网格遗漏，持续跨越只覆盖已测点；有限探针使 0.5 个百分点等细微变化不宜过度解释。0.40%—0.50% 的四点面板只有两个新顺序，不能确定连续剂量区间的边界或宽度。

账本保留了五类近似，尤其位置矩阵沿用原微批归一化且不反馈更新后的状态。其校准与参数位移的一致性提高了可解释程度，但不使逐行归因成为精确反事实效应。重放、重新评测和对既有输出的再分析不增加独立训练种子数。关键数字、字段、文件和适用边界列于随稿证据索引。

8 结论

本文把后门快速形成拆成顺序干预、模块承载和逐行增长解释三个可以分别检验的问题。在指定 LLaVA 配置中，完整数据顺序影响形成时间，部分效应由干净序列参与塑造；终态触发差分可定位到一个留出探针上有效的 LoRA 模块集合；经优化器状态校准的逐行账本能够重构参考轨迹的增长。但固定效应水平尚不能为所有测试顺序计时，训练期反例也表明静态承载不等于不可绕过的形成路径。由此，当前机制证据已超过曲线描述和热图观察，其边界停在跨顺序预测及同一承载集合的训练期因果必要性。将这一边界保留在结论中，是后续建立可验证形成机制的起点。

参考文献

1. Connor, M. & Emanuele, V. (2022). *Rethinking Backdoor Data Poisoning Attacks in the Context of Semi-Supervised Learning*. arXiv:2212.02582.
2. Turner, E., Soligo, A., Taylor, M., Rajamanoharan, S. & Nanda, N. (2025). *Model Organisms for Emergent Misalignment*. arXiv:2506.11613.
3. Arnold, J. & Lörch, N. (2025). *Decomposing Behavioral Phase Transitions in LLMs: Order Parameters for Emergent Misalignment*. arXiv:2508.20015.

4. Hu, E. J., et al. (2021). *LoRA: Low-Rank Adaptation of Large Language Models*. arXiv:2106.09685.
5. Lasnier, T., Antoun, W., Kulumba, F., Sagot, B. & Seddah, D. (2026). *Language Triggers Hijack Language Circuits: A Mechanistic Analysis of Backdoor Behaviors in Large Language Models*. arXiv:2602.10382v3.
6. Pruthi, G., Liu, F., Sundararajan, M. & Kale, S. (2020). *Estimating Training Data Influence by Tracing Gradient Descent*. NeurIPS. arXiv:2002.08484.
7. Xia, M., Malladi, S., Gururangan, S., Arora, S. & Chen, D. (2024). *LESS: Selecting Influential Data for Targeted Instruction Tuning*. ICML. arXiv:2402.04333.
8. Lelle, T. (2026). *Token-Level Generalization in LoRA Adapter Backdoors: Attack Characterization and Behavioral Detection*. arXiv:2605.30189.