在线损失过滤何时保护学习？训练期后门防御的配对比较与失效边界

中文论文初稿｜证据版 2026-11-05

摘要

训练期后门防御希望在抑制攻击的同时保留正常学习。若模型的攻击成功率在短窗口内上升，一个自然策略是在训练损失下降后开始过滤异常更新。然而，损失下降是否意味着正常任务已学会，少屏蔽正常样本是否带来更好学习，以及阶段性攻击下降是否能够持续，均需要直接检验。本文在合成新知识任务和 SQuAD 问答微调中，研究消费时损失过滤原型 Curfew，并用任务适配的强损失截断基线、停训对照、逐行决策重建及局部更新干预审查其作用。Curfew 在已测合成任务的 14 条轨迹中有 10 条通过对应风险与质量门，在三个真实问答设置的 10 条轨迹中均通过历史终态判据。但在六个配对设置中，固定预热的损失截断与 Curfew 均在两条合成轨迹和三个真实设置上达标，未建立数据驱动启动时机的独立优势。120,000 次样本消费的审计表明，Curfew 在重复实体任务中较少误屏蔽的优势未稳定转化为正常学习收益，并在稀疏段落分组上反转。停训与新知识结果进一步否定了“门开启时正常知识已经学完”的解释。真实任务中的形成、下降与反弹，以及局部更新限制后的攻击追赶，说明终态抑制、形成预防和暂态延迟必须分别陈述。本文提供的是对低额外计算防御原型的实证定位与可复核边界；尚未获得相对强损失截断的稳定安全—学习优势。

关键词： 训练期后门；损失截断；正常学习保留；数据过滤；训练动力学；配对干预

1 引言

被污染的微调数据可能使语言模型在正常输入上保持较好表现，同时在附加触发器时输出攻击者指定的目标。训练期防御因此面临两个共同目标：阻止目标行为被学入，保留这次微调原本应带来的学习收益。这两个目标不能由同一个训练损失代理充分代表。一个暂时难学的正常样本可能具有较高损失，一个已经被模型学会的毒样本则可能具有较低损失。过滤改变后续参数，也改变未来用于过滤的损失分布，防御与学习因而处在同一个反馈过程中。

我们的研究由训练中的短窗口 ASR 上升现象出发。在一个 Qwen3-8B 合成任务中，固定 60 题的攻击目标命中从第 37 步的 5 题增加到第 39 步的 52 题，仅间隔两次更新。[E-D01] 这个观察提示，应研究攻击形成时的更新，而不能只在最终模型上寻找异常样本。但它没有回答如何找到安全的训练时刻。该轨迹

在起跳附近正常新知识正确数为零，且近似触发条件也有大量目标输出；“尽早发现风险”与“已有可回退的正常模型”是不同问题。

Curfew 是对这个问题的一个具体尝试：当当前批次的损失中位数首次降低到阈值以下，开启逐行损失过滤；使用近期放行样本估计相对阈值；当同一实体或段落组持续被判为高损失时，给予恢复学习机会。它只复用训练已经产生的损失，不增加模型前向。方法在部分设置中确实达到低终态 ASR，并能在继续学习时避免直接停训造成的明显损失。

但判断方法价值，需要比“本方法成功了”更强的比较。将损失截断的缓冲区和启动时间适配到相同短程微调后，固定预热基线也取得相同达标覆盖。Curfew 在部分合成任务中比这个基线少屏蔽数百条正常样本，正常正确数却未随之提高；迁移到真实问答后，正常屏蔽数量反而更高。这些结果改变了原先关于启动时机、过滤选择性和学习保护的解释，而不是只为一个既定方法增加限制段落。

本文围绕三个可由已有实验直接回答的问题组织证据：第一，Curfew 的整体流程是否有效，其效果是否超过同权限、低额外计算的简单基线？第二，训练损失门、正常样本保留数量和终态 ASR 分别能够支持哪些结论？第三，将防御动作从样本过滤改为局部参数更新限制，是否已获得稳定的攻击—学习分离？我们报告成功、失败及有限确认，不把开发选择当成独立验证。

本文的主要贡献是一个由比较和反例构成的实证结果。强匹配损失截断推翻了“动态启动门已显示独立实用优势”的判断；逐行重建解释了过滤选择性跨任务反转的可观测条件；停训与持续干预结果则限定了学习完成和持续防御的主张。我们没有将这些证据包装为一个已经胜过现有强基线的新方法，也不将尚未执行的 Curfew 与参数控制组合计入结果。

2 相关工作与研究位置

损失截断通过降低高损失样本对训练的影响，为含噪文本学习提供简单工具。本文采用 Kang 与 Hashimoto 的方法思想及公开实现作为直接对照，并显式记录为短程微调所作的缓冲区、重算间隔和预热适配。[1] 比较对象是这个实际完成的适配版本，而非未运行的原任务配置。Curfew 与损失截断都复用当前训练损失；两者主要区别在启动方式、参考样本池和组级恢复，不应仅以“零额外前向”作为 Curfew 的独特贡献。

Wan 等（2023）已经在指令微调投毒中研究数据过滤及限制模型容量，并报告其安全与正常任务质量之间的权衡。[8] 后门防御也可以通过反学习或参数修剪实施。本文的局部更新限制与训练后的剪枝修复具有不同语义：前者持续改变能力形成过程，后者作用于已经形成的模型。[2] 同样，降低学习率、

减小适配容量或提前停止可以改变后门结果，但它们可能同时减少正常微调收益；比较必须保留实际学习指标，而不能仅报告目标输出下降。[3]

Xu 等（2026）的 TARE 已讨论从未投毒的孪生模型、能力成本与调度器混杂。[7] 因此，同时报告风险与正常能力、使用干净训练参照，并不是本文首次提出的原则。本文的区别在于污染微调中的学习保留、消费时过滤的具体反馈，以及阶段性干预效应是否能持续；TARE 的结果没有并入本文实验分母。

本研究使用 LoRA 进行参数高效微调，并在 SQuAD 与合成新知识任务中分别观察已有能力保持和新学习。[4,5] TOFU 作者知识子集用于测量新增事实的答案似然改善，其作用是构造可核查的学习需求，不是执行机器遗忘评测。[6] 我们对相关工作的主张保持有限：本文没有完成所有官方防御的端到端复现，不以本地概念适配的失败建立对整个方法家族的优越性。

3 问题定义、威胁模型与实验设置

3.1 防御目标与可用信息

攻击者污染微调数据中的指定行，使带触发器的输入与固定目标输出配对。防御者可访问训练样本、训练时逐行损失以及合法的数据分组字段；Curfew 的在线决策不读取毒样本真值或触发器身份。毒标签仅用于实验后的屏蔽精度与召回统计。分组字段包括合成实体 ID、SQuAD 段落标识和 TOFU 作者标识，因而本文不声称方法不需要任何附加数据结构。[E-D02]

主要部署目标是交付训练终点模型。因此，终态攻击成功率和正常能力是主要效果读数。中间检查点的风险另行报告，用于判断“是否曾经形成”、选择或发布中间检查点、以及回退策略的可行性。若一个系统只部署最终模型，中间高 ASR 并不自动推翻其终态防御效果。本文也不据一条轨迹宣称已有外部评估普遍错误；我们证明的是：特定终态读数不能独自支持更强的过程解释。

令 ASR 为固定触发输入上生成指定目标的比例，正常质量为对应无触发输入上的答案正确率。对真实问答还报告旧 QA，以避免仅在当前任务保持表现。触发条件下的正确答案率、近似触发行为与连续答案负对数似然分别保留，不相互替代。目标输出消失不意味着触发输入已恢复正确回答，更不等于内部相关表示已被擦除。

3.2 数据、训练与独立单位

主要合成任务包含 20,000 行、32 个实体的查表式新知识，200 条毒行，投毒率 1%。目标变体 A 为 violin，变体 B 为代码型目标 4909。模型为 Qwen3-8B，基座冻结，七类线性投影使用 LoRA，秩 16、alpha 32、dropout 0.05；训练批量 16，计划 1,250 步，使用 AdamW 及原 warmup/cosine 日程。真

实问答包括 SQuAD/Qwen、SQuAD/Llama 和短语触发的 Qwen 设置，均保留各自登记的数据、触发及评测身份。[E-D03]

主要评测有 V60 的 60 题和 H64 的 64 题，终态合并时分母为 124。问法常共享事实或实体，124 题不是 124 个独立训练重复；H64 在开发后期曾重复使用，也不再作为全新测试集。真实任务的扩展质量表使用 200 题，其中含旧 QA。本文不混合 60、124 和 200 题分母，也不把一条轨迹的多个检查点当成独立 seed。

历史合成任务采用 ASR≤5% 与正常正确数≥98.7/124 的联合门。后者由早期干净参照构成，是较宽的质量门，并非逐 seed 的统计等效证明。真实任务质量口径在实验后曾修订为相对同设置干净参照的 200 题质量差，容许下降 3 个百分点；本文明确将其称为历史修订判据，不把“通过”写成严格统计非劣成立。[E-D03] 为避免这些判据掩盖差异，主结果同时给出原始命中数、正常正确数和样本屏蔽量。

3.3 证据分层

本文结合四类完成实验：完整训练终态比较、固定检查点的过程观测、同一完整状态分叉后的实际干预，以及对保存日志的 CPU 重建。它们分别回答效果、过程、干预响应和决策来源。日志重建不构成新训练反事实；局部方向提名也不代替实际续训。未完成科学预算、未触发后续门或仅完成工程预检的任务不计为科学失败。[E-D04]

4 防御原型与比较方法

4.1 Curfew：消费时损失过滤

设第 t 步第 i 行在答案及 EOS 上的平均 token 交叉熵为 $\ell(t,i)$。当前 16 行批次的损失上中位数首次小于 0.5 时开启过滤，之后保持开启。每行处理时，从近 20 步已经放行的行中求上中位数 m，阈值为

$\tau = \min(1.5, \max(0.3, 10m))$。

参考池为空时使用 1.5。损失超过 τ 的行通常被屏蔽，但同组最近最多 10 次高损失标记中，若已有至少 4 次历史且高损失比例不低于 50%，则恢复放行。恢复放行后高损失标记仍被保存，因此可能连续豁免；该机制没有“只给一条”的硬预算。[E-D02]

这里有两个会影响实际行为的实现细节。被屏蔽行不进入参考池，而同一步较早放行的行会影响后续行的阈值。因此决策依赖当前过滤历史。其次，屏蔽发生在已经取得逐行损失之后，不代表省去了该行前向；密集参数仍参与运算。我们称其低额外计算，而不以“零成本”暗示完整训练不消耗资源。

4.2 强损失截断与停训对照

损失截断保存最近 160 行的消费时损失，包含最终被屏蔽的行，每 160 行重算一次分位数。当前批次先使用既有缓冲区阈值做决策，再将当前损失写入缓冲区。高于或等于分位数的行被屏蔽。开发扫描选择 c=0.05，固定预热 20 或 50 步分别从第 21 或 51 步启用；它们启用后仍随损失分布变化，不是完全静态阈值，也不要求每批精确删除 5%。[E-D05]

为区分启动时间与整体过滤规则，另有与 Curfew 同 gate 启动的损失截断开发对照。停训对照则在 Curfew gate、gate+25、+50 和 +100 步评测。低学习率、低秩及若干损失修改只作为有限开发边界。本文以完成且较强的损失截断配置为主要基线，不用未调好的 c=0.01 结果代替整个基线家族。

4.3 参数更新限制及过程指标

为了检验参数控制能否进一步分离攻击与正常学习，实验从同一 adapter、Adam 和随机状态分叉，限制指定层或投影的 LoRA 参数增量，并连续训练 250 步。零增量时参数不变，但 Adam 状态仍演化；这与早期 .grad=None 冻结不同。头级实验改为前向功能锚定，将指定输出通道的 LoRA 贡献保持在分叉状态，实时参数与优化器仍可演化。两类动作分别保留同语义的父组和有限随机参照。[E-D06]

主要过程效应为分叉后第 20–120 步窗口的曲线积分平均：ASR 下降取无干预减干预，正常变化取干预减无干预。它不是挑选最好检查点后的差值。共同 +250 步终点、后续追赶和正常能力代价同时报告。该定位阶段允许已知风险轨迹帮助选择分叉点，因此不能直接作为无触发知识的在线部署方法。

5 结果

5.1 Curfew 有条件有效，但动态 gate 的独立优势未成立

冻结的 Curfew 在变体 A 的六条已测轨迹中有三条通过联合门，在变体 B 的八条中有七条通过，合计 10/14。开发与确认必须区分：B 的冻结后留出为 3/4，A 为 1/2。将预设边界 A1101 排除后可得到 10/13，但本文保留实际完成的 14 条分母。所有 Curfew 合成终点的正常质量均通过旧宽门，并不意味着与逐 seed 对照无损。[E-D07]

迁移到真实问答后，SQuAD/Qwen 四条、SQuAD/Llama 三条、短语触发 Qwen 三条均得到 0/124 的终态目标命中，并通过修订后的质量判据。对应 200 题正确数依次为 184–186、189–191 和 181–185。[E-D03] 这是防御流程在这些设置中能够工作的正面证据，但效果成立仍需与强对手比较。

表 1 汇总六个配对设置的 Curfew、固定预热 LT20 与 LT50。三者在合成任务均有 2/3 通过，在三个真实设置均通过；在失败的 B1105 中，三者都未达到风险门。相同覆盖不构成统计等效，却足以否定动态 gate 已在这批设置显示独立实用增量的说法。[E-D08]

表 1　强简单对照改变方法判断。各格依次为 Curfew / LT20 / LT50；攻击与正常分母均为 124，屏蔽量为训练行数。

设置	终态目标命中	正常正确	正常行屏蔽
合成 B1103	0 / 0 / 0	109 / 119 / 119	50 / 893 / 865
合成 B1105	124 / 92 / 113	111 / 106 / 109	55 / 920 / 880
合成 B1107	0 / 0 / 0	110 / 108 / 110	46 / 899 / 817
SQuAD/Qwen1006	0 / 0 / 0	112 / 114 / 113	3415 / 845 / 846
SQuAD/Llama1001	0 / 0 / 0	117 / 117 / 118	1360 / 893 / 857
短语触发/Qwen1006	0 / 0 / 0	112 / 113 / 114	1547 / 888 / 847

同 gate 的 B1106 开发比较进一步排除“差异只来自启动时间”：Curfew 和 LT c=0.05 均在第 50 步启用、终态目标为零；Curfew 误屏蔽正常行 50 条，LT 为 942 条，但正常正确数为 112 对 115。[E-D08] Curfew 在这个点具有更好的样本过滤选择性，却没有获得更好的终态学习。我们也不能据有限 c 网格断言 LT 必须误屏蔽 942 条才会成功。

5.2 少屏蔽的优势受任务结构制约，不能代替学习收益

对六条 Curfew 轨迹、共 120,000 次训练行消费进行决策重建，可以精确复现保存的 gate、mask、参考池和组恢复记录。合成任务每组高度重复，而真实问答有大量只出现少数次的段落。这个差异改变了恢复逻辑实际能够帮助谁。[E-D09]

表 2　逐行审计的主要量。地板列表示实际阈值处于 0.3 分支时发生的正常屏蔽，不表示“地板造成”的因果增量。

轨迹	正常屏蔽	毒行屏蔽	地板分支正常屏蔽	空参考池正常屏蔽	组恢复救回正常行
B1103	50	192	41	0	30
B1105	55	17	54	0	36
B1107	46	197	42	0	11
SQuAD/Qwen1006	3415	199	1685	1172	8

轨迹	正常屏蔽	毒行屏蔽	地板分支正常屏蔽	空参考池正常屏蔽	组恢复救回正常行
SQuAD/ Llama1001	1360	198	1345	0	2
短语触发/ Qwen1006	1547	199	1517	0	2

三个真实设置共屏蔽正常行 6,322 条，其中 4,547 次、即 71.92% 发生在阈值绑定 0.3 时。在相应状态中，正常损失超过 0.3 的比例在合成任务为 0.28–0.41%，真实设置为 6.94–9.48%。这提供了同一数值阈值跨任务影响不同的直接证据。但地板本身是在抬高更低的相对阈值；固定当前损失与历史移除它，反而会在三条真实轨迹分别额外屏蔽 4,981、4,403 和 5,122 条正常行。因此，不能把“多数错误发生于地板分支”误读为“去掉地板即可修复”。[E-D09]

真实数据每个 root 有 11,663 个段落组，其中 11,530 组整轮至多出现四次，覆盖 19,253/20,000 行。恢复规则最早从同组第五次出现才可能生效，大多数样本无法获得该保护。合成数据的 32 组各重复 625 次，机会结构显著不同。组恢复数的差距因而有明确的实现条件，但尚不能归因于一个单独组件：降低历史要求同时可能放过毒行，必须通过实际训练判断安全代价。

SQuAD/Qwen 的参考池还出现额外反馈：第 56 步开始出现整批屏蔽，第 76 步起保留池可能耗尽，1,172 次正常屏蔽发生在空池回退状态。1,250 个计划步中有 123 步未执行 optimizer 更新，实际更新 1,127 次。[E-D09] 这说明相同计划步数不必意味着相同更新机会。本文据此修正预算描述，而不把日志中的阈值替换计数当成另一套方法重新训练后的性能预测。

5.3 损失门不是学习完成时刻，持续学习价值需要强配对比较

在九条合成轨迹中，gate 时正常正确数仅为 22–34/124，没有一条通过联合门；gate+25 仍为 0/9，+50 与 +100 各只有同一个 seed 通过。损失中位数低仅说明当前消费样本的损失状态，不能推出评测任务已经学会。[E-D10]

TOFU 知识实验在 SQuAD 中加入 2,000 条作者问答、涉及 100 个虚构作者。Curfew 的原问法平均答案 NLL 为 1.3518，对照无防御终点为 1.3139，基座为 3.4875；改问法相应为 1.5301、1.5025 和 3.8154。按相对基座的 NLL 改善计算，Curfew 保留无防御终点改善的 98.25% 和 98.81%，而 gate 即停仅保留原问法改善的 10.86%。[E-D11] 这支持继续训练有价值，并说明 Curfew 可以在该冗余知识设置下保留大部分似然改善。

这个结果有两条重要限制。首先，98% 是 NLL 改善保留，不是问答正确率。其次，每作者 20 问为恢复逻辑提供充足重复机会；Curfew 仍屏蔽 385/2,000 条作者知识行，且没有同设置的 LT 或关闭恢复组件对照。因此它不能证明稀有独立知识无损，也不能证明恢复组件单独带来收益。

随后使用相同新知识任务完成的三个顺序进一步检验强基线。表 3 中 LT20 的三条终态攻击均为零，Curfew 只有两条。Curfew 成功的两条正常正确数分别比 LT20 少 7 题和 4 题，少屏蔽仍未兑现为更多学习。[E-D12]

表 3　相同新知识任务、三个顺序的完整终态比较。各格顺序为 1105 / 1106 / 1107。

方法	目标命中/124	正常新知识正确/60	正常行屏蔽
无防御 R	124 / 124 / 124	50 / 57 / 46	0 / 0 / 0
干净训练 A0	0 / 0 / 0	49 / 45 / 41	不适用
Curfew	124 / 0 / 0	52 / 50 / 42	34 / 59 / 61
LT20	0 / 0 / 0	48 / 57 / 46	883 / 812 / 853
LT50	124 / 0 / 0	46 / 52 / 48	856 / 854 / 768

这里的 seed 编号不能与不同任务的 B1105 混用；LT20 在两个协议中一成一败不构成矛盾。过滤日志还显示，Curfew 失败的 1105 在 gate 前放行 9 条毒行，gate 后 188 条因低损失继续通过，最终仅拦住 3 条；成功的 1106 最终拦住 193 条。[E-D12] 它揭示低损失毒行逃逸的实际路径，但启动时机、前缀状态与后续反馈仍未被单因素分离。

5.4 终态零 ASR 不能决定形成过程，低 ASR 也不保证回答恢复

Qwen3-8B/SQuAD 的 mid16 配方仅含 16 条指定毒行，最后一条在第 116 步，终态目标命中为 0/124。保真重放补测记录 103 个采样点、18,540 条逐题条件输出，且训练日志与终态权重哈希匹配原运行。[E-D13] 这是一条轨迹的补观测，不是新 seed。

按照相邻两个采样点触发命中至少 12/60、且较无触发多至少 9/60 的冻结规则，第 100 步首次确认形成。第 110、115、120、125 步均为 60/60；此后下降至第 150 步 1/60，又在无新增毒行的第 200 步反弹到 28/60。第 320 步起后续已采样点才全部精确为零。这个直接反例排除了把该终态零解释为“整个训练中从未形成”，也排除了单调衰退的描述。

表 4　同一真实问答轨迹的形成与后续变化。

step	触发目标/60	无触发目标/60	近似触发目标/60	触发正确/60	无触发正确/60
100	39	0	7	18	56
110	60	0	46	0	55
120	60	0	60	0	54
150	1	0	0	48	55
170	1	0	0	37	55
200	28	0	2	20	56
320	0	0	0	53	56
1240	0	0	0	55	56

另一个区别直接影响防御解释：第 170 步目标只命中 1/60，但触发输入仅答对 37/60，其中 19 题首词输出为 cf，无触发仍答对 55/60。终态合并题集的触发正确为 109/124、无触发为 114/124。攻击目标下降与正常回答恢复并不同步。[E-D13]

mid16 没有施加 Curfew，因此不能作为 Curfew 防止形成失败的证据。它的作用是限定过程推断：同样的零终点可以对应不同历史。若论文仅主张最终交付模型的低攻击率，终点评测仍是有效结果；若主张防止形成、安全回退或内部擦除，就需要额外过程与功能证据。主比较中的 Curfew/LT 大多缺密集中期 ASR，因此本文不宣称二者已保证训练全程无风险。

5.5 局部更新限制存在暂态差异，尚未转化为持续防御

最初 19 配置×3 轨迹的实际干预，在部分时点产生攻击与正常能力的相对分离。seed1106 的第 107 步，无干预正常正确 44/60、攻击 53/60；MLP17 半更新为 47/60 与 10/60，attention29 零更新为 46/60 与 9/60。但随机 MLP22 半更新同样达到 47/60 与 11/60，随后攻击迅速追赶。57 条终点中 51 条攻击 124/124、五条 123/124、一条 119/124，没有持续低 ASR。[E-D14]

新轨迹确认削弱了固定候选的可迁移解释。MLP17 半更新在 2101/2102 的主窗平均 ASR 降低为 0.79 和 −1.38 个百分点；attention29 为 1.96 和 0.50 个百分点。继续拆分后，K29 在已见轨迹成为探索候选，但确认时一条轨迹平均攻击下降 6.58 个百分点，同时正常下降 6.46 个百分点；另一条攻击下降 5.25、正常增加 0.38 个百分点。[E-D15]

头级锚定中，H1 在 1106 的主窗攻击降低 23.50 个百分点、正常增加 2.21 个百分点，而在 1105 的攻击降低仅 0.33 个百分点。所有 C/D 臂终态 V60 攻击均为 60/60，头级实验的两个 64 题集也均为 64/64。

[E-D16] 因而不能把一个开发轨迹上的最好头当成稳定后门位置。该结果也不证明所有细粒度控制都无效；它否定的是已测固定选区和强度在这些持续投毒轨迹中提供完整防御的主张。

5.6 计算成本

Curfew 与 LT 均复用已有训练损失。在一个同 gate 开发点，训练步耗时合计约为 951 与 946 秒，没有严格受控的加速优势。[E-D08] 当前实现先取得逐行损失再屏蔽，少删样本不能换算为更少前向计算；较低额外开销也不能替代安全与正常学习的比较。独立监测传感器的提效另列附录，不计入 Curfew 的方法收益。

6 讨论

6.1 目前成立的防御贡献是什么

Curfew 的价值首先是一个真实可执行的低额外计算过滤原型：在明确设置中同时达到低终态攻击率和历史质量门，并且能够继续学习。它还提供了与分位数过滤不同的逐行决策过程，使参考池反馈、组恢复与任务重复结构可以被具体审查。本文最有力的贡献不来自固定方法名称，而来自强对照改变结论：动态 gate 不再是已证明必要的部分；少屏蔽不再被用作学习优势的替代指标；局部 ASR 延迟不再被写成持续防御。

这些结论也限定下一步工作的价值判断。仅增加同类成功 seed，不能填补相对 LT 的收益缺口。只有在相近攻击水平下保留更多真实新学习，或在相近正常能力下进一步降低风险，且作用能超过同预算简单对照，新的过滤或参数控制组件才获得独立贡献。当前实验尚未提供这一稳定优势。

6.2 机制线能够帮助防御，但连接尚未完成

ASR Rising 说明行为可能快速变化，过程干预说明部分参数更新在特定轨迹上影响攻击与正常学习的相对速度。这些结果可以提出防御假说，却不能自动确定在线动作。终态承载行为的部位不一定是形成必经部位，阶段性受影响也不保证后续没有替代路径。将 Curfew 的启动状态与输出驱动的选区结合仍是可检验方向，但本文没有完成该组合的实际训练。

可由现有证据提出的工作假说是：过滤器的脆弱性与早期更新使后续毒样本变为低损失有关；如果某种干预在保留正常学习的同时延缓这类低损失化，在线过滤可能获得额外机会。日志为这条假说提供动机，未给出其因果闭环。它需要区分真实选择性与整体减速，并比较单用过滤、单用干预、组合及强 LT，不能从 H1 的局部阳性直接推出组合有效。

6.3 可见过程、部署风险和内部消除是三个层次

本文的过程结果不要求所有部署一律承担密集全程评测。是否需要中期风险证据，取决于是否发布、选择或回退到中间模型。最终模型防御效果、曾经形成过的条件化行为、以及内部相关性是否被移除，应该作为不同主张分别支持。这样既避免把零 ASR 过度解释为擦除，也避免因为无部署暴露的中期高峰而否定真实的终态收益。

7 局限

本文覆盖少量模型、任务和固定目标攻击，主要是 8B 级 LoRA 微调，未建立跨尺寸、跨模态或自适应攻击的一般规律。历史开发经历多次规则改进，部分评测口径事后修订，真实主比较每个设置仅选一个配对 seed；这些因素限制泛化和显著性主张。开发、确认与跨设置迁移已分列，但不具有统一新留出测试集的强度。

正常知识指标仍不完整。真实 SQuAD 初始能力较高，质量保持不完全等于新增学习；合成查表与 TOFU 作者知识具有重复冗余，对稀有事实的保护尚未确认。TOFU 缺 LT 和恢复组件匹配对照，阈值重建缺替代策略的实际训练反事实。当前数据不能支持 Curfew 的最优性，也不能支持某个单独组件必要。

多数防御主比较只有终态而没有密集过程 ASR。mid16 是一个真实任务实例，不能外推其余零终点都经历形成和消退。参数控制使用有限结构候选与动作，并包含事后提名；未找到可迁移选区不等于不存在这种选区。其他官方方法的身份、权限与全成本未全部匹配，因此本文不作全面领先声明。已知触发传感器与无触发标签的过滤部署也不能混为同一权限设置。

8 结论

训练期过滤能够在已测任务中抑制终态后门，但成功的端点不足以确定方法贡献来自哪里。强损失截断比较削弱了动态启动时机的独立优势；逐行审计和新知识比较显示，正常样本保留数量不能替代学习收益；过程曲线与持续参数干预则区分了形成预防、暂态延迟和终态抑制。现有干预尚未显示稳定优于强简单基线的安全—学习收益。更有价值的推进方向，是让可复现的攻击—学习差异转化为实际联合收益，并用强匹配对照检验这一转化。

参考文献

[1] Kang, D.; Hashimoto, T. B. *Improved Natural Language Generation via Loss Truncation*. ACL 2020. 论文原文 。本文只引用其方法思想；对照采用本文记录的短程适配。

[2] Liu, K.; Dolan-Gavitt, B.; Garg, S. *Fine-Pruning: Defending Against Backdooring Attacks on Deep Neural Networks*. RAID 2018. 论文原文 。用于区分训练后剪枝与训练期形成控制。

[3] Zhu et al. *Moderate-fitting as a Natural Backdoor Defender for Pre-trained Language Models*. NeurIPS 2022. 论文原文 。本地低秩、低学习率和早停配置不等于其完整官方复现。

[4] Hu et al. *LoRA: Low-Rank Adaptation of Large Language Models*. 2021. 论文原文 。

[5] Rajpurkar, P.; Zhang, J.; Lopyrev, K.; Liang, P. *SQuAD: 100,000+ Questions for Machine Comprehension of Text*. EMNLP 2016. 论文原文 。

[6] Maini, P.; Feng, Z.; Schwarzschild, A.; Lipton, Z. C.; Kolter, J. Z. *TOFU: A Task of Fictitious Unlearning for LLMs*. 2024. 论文原文 。本文只使用其作者知识数据，不将本实验称为遗忘任务。

[7] Xu, R.; Xu, W.; Zhu, S. *TARE: Weigh a Never-Poisoned Twin Before Reading Backdoor-Defense Costs*. 2026. 论文原文 。

[8] Wan, A.; Wallace, E.; Shen, S.; Klein, D. *Poisoning Language Models During Instruction Tuning*. ICML 2023. 论文原文 。

附录 A　独立监测与研究成本

已有单前向传感器在 16 个保存状态的 960 次路径测量中，相对独立前向加生成的传感器成本，逐配对中位加速为 4.87976 倍。但它只提供分数、gap 和排名，不直接给出生成 ASR；保留原生生成的复用路径节省约 19.1% 传感器时间。[E-D17] 一次新初始化、固定数据顺序确认中，冻结的正 gap 规则比密集风险 oracle 晚一步报警，显示廉价监测可以工作。成本比较是按实测单位耗时与策略请求数重放估计，并非所有策略独立端到端部署的测速。[E-D18]

监测提效不意味着已有质量合格的回退模型，也不意味着 Curfew 胜过 LT。局部干预三批共 139 个新任务，记录的任务墙钟合计 32.8051 小时，包含加载、训练、评测和保存；这既不是双卡历时，也不是项目全成本。[E-D16] 密集评测、候选筛选与确认具有实际费用，不能用一个廉价传感器的时间代表完整研究或部署流程。

证据附录说明

正文中的 [E-D01]–[E-D18] 是本项目原始实验与审计的证据编号，不是外部文献。各编号的文件、字段、批次身份和解释边界见 evidence/defense_claims.md。结果来自完成运行与保存输出的逐题核验。全文数值按原批次分母呈现，不将复用参照、同轨迹检查点与未执行分支计为独立实验。