两篇成稿之后：研究位置与分合判断

2026 年 11 月 5 日。本文依据同期两篇完整初稿与随稿证据索引判断。它是研究定位，不是实验执行合同，也不预测会议录用结果。

1 写成文章后，位置比“离好论文多远”更清楚

机制线已经有可写成主结果的局部因果证据，防御线已经有实际有效的流程；两者尚未分别成为完整形成解释和有独立优势的新防御。 这两个判断可以同时成立。不能因为机制还没闭环而说我们只见过曲线，也不能因为强 LT 表现好就说 Curfew 完全没用。

机制稿的主轴已经能写成一句话：固定模型、毒集与预算时，完整训练顺序影响后门形成；终态触发差分可以定位到部分 LoRA 模块，增长可以被逐行优化账本近似重构，但这两项尚未转化成跨顺序的形成时钟。它的价值来自这些实际干预与读数之间的具体关系。把“何时出现”和“由哪里承载”分开，只是论证框架，真正承担贡献的是框架中的测量和反例。

防御稿的主轴也已经明确：在线损失过滤在指定任务上能够抑制后门，但自适应启动、少删正常样本和暂时降低 ASR，均未稳定兑现为更好的最终安全—学习权衡。强固定预热、逐行日志、新知识对照和共同终点改变了我们对原型的判断。文章有实质内容，不过它目前适合防御实证研究的身份，不能按一项已经胜出的新方法来写。

2 两篇各自已经拿到了什么

稿件	已有最强证据	现在能成立的中心表述	仍不能写成的表述
机制	顺序×训练种子与毒骨架/干净填充干预；M1 的 32/224 模块留出定位；M2 起飞时承载；M3 增量重构	指定配置中，完整序列影响形成时间；空间承载可以定位，但承载量不是已验证的统一时钟	找到了通用后门电路；解释并预测全部顺序；冻结该集合即可能力无损防御
防御	Curfew 的 10/14 合成与 10/10 真实轨迹历史联合门；强 LT 比较；120,000 行决策审计；新知识与共同终点	在线过滤确有条件性效果，样本选择性与最终学习收益之间存在实测断点	动态 gate 不可替代；Curfew 稳定优于强 LT；局部参数控制已提供持久安全收益

上述通过率不是来自同一个统一实验，也不是方法总体成功概率。机制篇的 F=1.081、E=0.023 是归一化触发差分 margin，不能当成 ASR 的恢复与残留比例。防御篇的历史质量门也不能当成已经完成统计非劣检验。

ASR Rising 在两稿中有不同作用。在机制稿里，它是需要解释的对象，并由跨模型轨迹说明现象并非单个偶然曲线；在防御稿里，它是研究训练过程和干预持续性的动机。两篇可以共享必要背景，但未来若独立投稿，需要各自有独立的中心贡献和主结果，不能把同一批跃升曲线重复算两份主要贡献。

3 机制篇：立住与做实之间的界线

按范围明确的机制实证论文来写，现有材料已经有论文形态。 稿件能够连续回答：顺序是否影响行为、干净序列是否参与、终态哪些模块承载差分、这一集合何时出现作用、逐行账本是否忠实、哪些简单预测失败。它不是只剩一个设想。

但若希望中心主张升到“解释形成机制”，还缺一个有区分力的连接：用已经固定的候选对象或读数，在未用于挑选规则的训练轨迹上，事先预测一个实际干预后果，并区分该后果与随机位置、一般训练减速的效应。结果可以是可预测的延迟，不必强求永久防御成功；关键是预测对象、动作、行为读数和正常学习必须对应。

这不是承诺“一次实验就能解决”。它说明缺口的类型是因果连接，而不是曲线数量。若指定候选失败，应收缩或更换机制表述；增加十个模型的相似曲线不能替它过关。M2 的固定 D 阈值已经未通过，不能保留旧时钟再仅靠扩大容差修饰。

立住之后的做实才包括：更换毒集和顺序、不同初始化和剂量下的边界、更多任务或模型族、选择稳定性、生成 ASR 与连续读数的一致性、完整开销。需要多少扩展，应由最终主张范围决定。M1 的同一干预对正常能力和真实生成的影响，如果被用于主张“后门特异”，则应前移到立住阶段，不能后置为附加实验。

4 防御篇：必须区分两条成文路线

若目标是新防御方法论文，当前缺的是独立收益本身。 Curfew 的有效性已有证据；相对强 LT 的优势仍未建立。现有新知识比较中，LT20 三条终态均无目标命中，Curfew 只有两条；Curfew 成功的两条也没有因少删行而获得更多正常学习。局部 H1 的短窗改善在另一个轨迹上很弱，且共同终点追上。这些都应影响方法的中心主张，而不是藏到附录。

这一路线的立住条件，是一个事先固定、符合防御者信息权限的规则，在可比正常学习和共同预算终点上显示可确认的风险收益。比较应包含强 LT 与必要简单对照。若方法需要已知触发或毒标签来选候选，就要改写威胁模型；不能一边使用这些信息，一边声称无先验在线防御。Curfew 与参数控制的结合目前属于待验证假说，不能提前算成已有方法。

若目标是防御评估或实证论文，稿件已有可串联的具体发现，但主贡献还需更聚焦。 当前最有价值的是强基线使方法判断发生改变，以及少删正常行并未改善最终学习。若要进一步主张某类现行评价会误导，需要明确一个实际采用的比较决定、同条件反例和可执行的修正，并在独立流程中改变一个具体结论。不能只把“应同时看 ASR 和正常能力”当成新的评估原则。

尤其需要与已有成本归因、干净孪生等工作区分，例如 TARE 已研究如何分离防御自身对正常模型的影响。本文的候选增量是污染微调中的学习保留、消费时决策与持续性；不能把邻近工作的结论或实验并入我们的结果。

mid16 是清楚的过程反例：终态零不代表从未形成，低目标命中也不保证恢复正确回答。但若部署只使用终态模型，中期高 ASR 并不自动否定最终模型的表现。它对中途发布、选模和回退很重要；不能凭这一条轨迹推出整个防御评估领域都有漏洞。

立住之后，再扩攻击、正常任务、难样本、稀有知识、未知触发、超参数和模型族，以证明边界与稳健性。若独立优势或具体评价改进还没成立，这些扩展可能增加工作量，却不改变论文身份。

5 合成一篇，什么时候会更强

目前可以诚实地合成一篇“后门形成与抑制边界”的实证研究，但其中心会变宽。更多实验不会自动使因果链更完整，也可能削弱 M1–M3 的清晰度。

更有分量的合稿需要一条真正贯通的链：在同一研究系统中，机制读数提出一个可辨别的形成假说；该假说事先决定干预对象或时机；干预在正常学习约束下产生持续、可比较的风险变化；再用原来的机制量检验变化是否符合解释。这个连接可以只在一个受控体系先成立，之后再讨论范围。

现有 LLaVA 的 M1 集合与 Qwen 的 K29/H1 不是同一对象，终态关闭 LoRA 与训练期功能锚定也不是同一操作。不能将 M1 的强定位和 H1 的暂时抑制拼成“机制指导防御已经验证”；同样，H1 的追上不证明 M1 集合在形成期一定无效。

选择	当前收益	为何还缺证据
分开：机制实证 + 防御实证	两个问题和证据边界清楚，最适合现在阅读、修改和判断	分别需要提高中心发现的解释力与外部判断价值
分开：完整机制 + 新防御方法	如果将来都闭环，可形成两个独立贡献	目前形成连接、强基线收益都未完成
合并：机制指导防御	机制与用途在同一篇互相检验	必须先有同一对象、同一语义动作与长期收益的连接
合并：形成与抑制的实证边界	可以使用已有证据，避免虚构方法胜利	应缩窄问题并选择主轴，避免成为全部工作的总汇

参照此前 HanLab 总结里“观察、干预、利用、回到原量验证”的做法，我们更接近中间环节，而不是只差最后一轮大规模扩展。机制篇已经有操作下的局部解释，防御篇已经有实际效用；缺的是解释能够准确指向一个动作，以及该动作的收益由比较支持。这是对现有证据的判断，并不是借某个实验室风格保证投稿结果。

6 当前建议

先保留两篇独立初稿作为工作稿。机制篇以顺序敏感性、承载定位与计时失败的关系为主，避免承诺统一理论。防御篇以强匹配比较和学习保留为主，避免承诺已经领先。后续阅读和修改时只追问两件事：删去所有未来工作段落，本文还留下什么新的事实；一个读者据此会改变哪项解释或选择。

若机制规则随后能够决定一个可验证的训练动作，合稿的理由才会变强。若机制继续产生解释性结果而防御仍受强 LT 支配，两篇保持不同身份更合理。此时需要做的是选择中心贡献，而不是因研究工作很多就同时承诺两篇完整机制与方法论文。

完整数字、主张与源文件对应关系见随稿 evidence/mechanism_claims.md、evidence/defense_claims.md；独立审阅意见见 evidence/manuscript_review.md。